

Análisis Automático de Programas

Análisis dataflow interprocedural

Diego Garbervetsky
Departamento de Computación
FCEyN – UBA

Como analizar varios métodos?

```
int divByX(int x) {  
    [result := 10/x]1;  
}
```

```
void caller1() {  
    [x := 5]1;  
    [y := divByX(x)]2;  
    [y := divByX(5)]3;  
    [y := divByX(1)]4;  
}
```

- ¿Cómo sabemos que divByX no falla?

```
float area(Cuadrado c) {  
    [result := c.l*c.l]1;  
}
```

```
void caller1(Cuadrado c2) {  
    [Cuadrado c = newCuadrado()]1;  
    [float a1= area(c)]2;  
    [return area(c2)+a1]3;  
}
```

- ¿Cómo sabemos que área no falla?

Análisis interprocedural

- Analizar un programa compuesto por varios métodos
- Estrategias:
 - Construir CFG interprocedural
 - Asumir/Verificar
 - Sentividad a contexto
 - Inlining
 - Call string
 - Calcular “resúmenes”


CFG interprocedural

- Extender CFG para varios procedimientos
 - Un eje del **llamador** al **entry** del **llamado**
 - Un eje del **retorno** al punto siguiente al **call**

```
int doble(int x) {  
    [result := 2*x]1;  
}
```

```
int divByX(int x) {  
    [result := 10/x]1;  
}
```

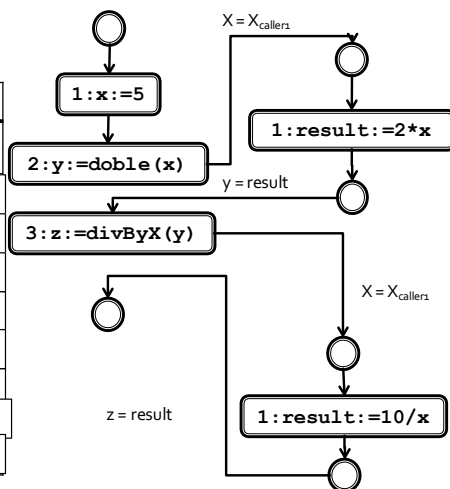
```
void caller1() {  
    [x := 5]1;  
    [y := doble(x)]2;  
    [z := divByX(y)]3;  
}
```



CFG interprocedural

■ Análisis de caller1

	caller1			doble		divByX	
Pos	x	y	z	x	res	x	res



Otro ejemplo


```

int doble(int x) {
    [result := 2*x]1;
}

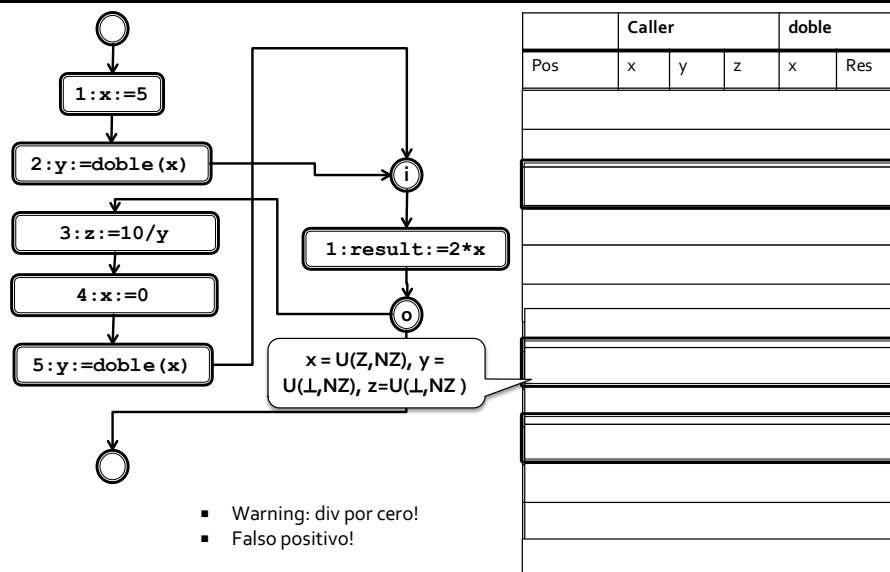
void caller1() {
    [x := 5]1;
    [y := doble(x)]2;
    [z := 10/y]3;
    [x := 0]4;
    [y := doble(x)]5;
}

```

¿Le ven algún problema?

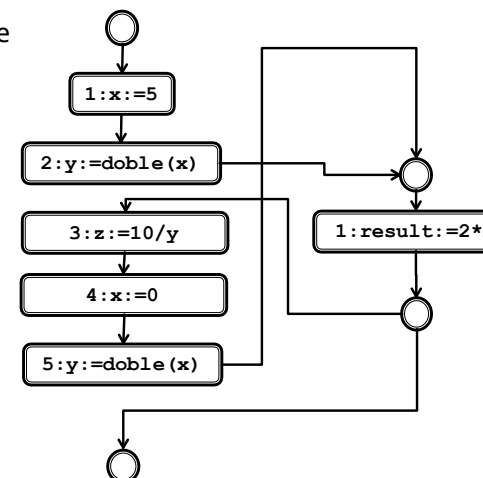


Otro ejemplo



Cual fue el problema?

- El CFG interprocedural pierde precisión
- No distingue diferentes contextos de llamada
- En particular puede recorrer caminos que en realidad no son factibles



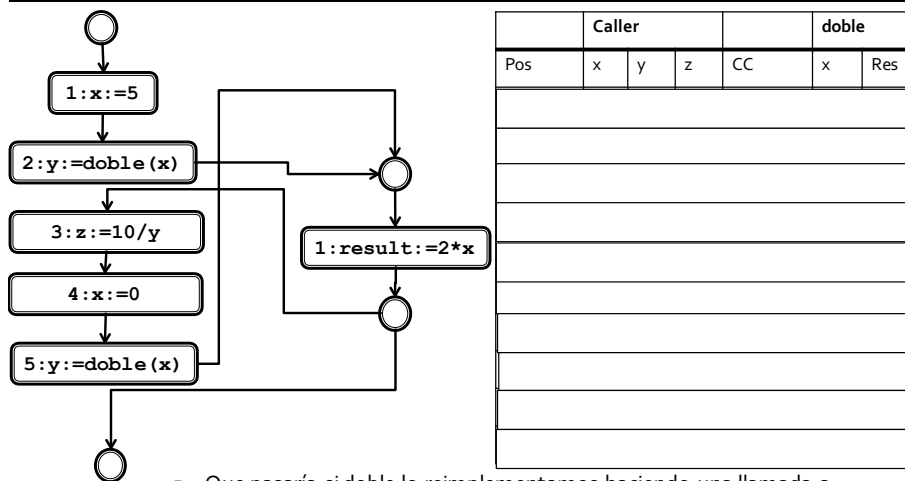
Sensibilidad al contexto

- Hay que distinguir entre los diferentes contextos de llamada a una función
- Varias técnicas
 - Cadenas de llamadas
 - Inlining/Cloning
 - Asumir/Verificar
 - Resúmenes por métodos

Cadenas de llamadas

- En runtime diferentes llamadas a un metodo (ej: doble) estan distinguidas por su call stack
 - En particular lo podríamos hacer por su parte de control (ej: $m1.4 + m2.1 + \dots$)
- Problema
 - El stack puede no tener cota
 - Recursión
- Idea:
 - Usar las las ultimas k llamadas para distinguir contextos
 - Se lo llama k-limit

Ejemplo revisitado – 1 limit



- Que pasaría si doble lo reimplementamos haciendo una llamada a otro método?
 - `int doble(int x) { return g(x); }`
 - `int g(int x) { return (2*x); }`

Recursión y cadenas de llamadas

```
int doble(int x) {
    [result := 2*x]1;
}
int g(int v)
{
    if(v>2)
        [return g(v-1)]1T
    else
        [return doble(v)]1F
}
void m(int x) {
    [y := g(x)]1;
    [z := 10/y]2;
}
```

- Es posible hallar un k que permita analizar este problema con precisión?
 - `m_1.g_1F.doble`
 - `m_1.g_1T.g_1F.doble`
 - `m_1.g_1T.g_1T.g_1F.doble`
 - ...
- Cadenas por llamadas requiere aproximación en casos recursivos

Cadenas de llamadas

Resumiendo:

- Se introduce al estado abstracto la noción de contexto utilizando una cadena que modela las últimas llamadas
 - Se conoce como **k-limiting**
- Para programas no recursivos se puede ser preciso
 - ¡Aunque no perfecto! Por qué?
 - (¡loops!)
- Para programas recursivos hay que aproximar varios contextos
 - Ejemplo: `m_1. (g_1T)*.g_1F.doble`
- Aunque parece una técnica interesante no se utiliza tanto
 - Costoso: multiplica la cantidad estados por la cantidad de caminos (¡puede ser exponencial!)
 - Depende fuertemente de tener un buen call graph

Sensibilidad al contexto

- Hay que distinguir entre los diferentes contextos de llamada a una función
- Varias técnicas
 - Cadenas de llamadas
 - **Inlining/Cloning**
 - Asumir/Verificar
 - Resúmenes por métodos

Inliling/Clonning

- Idea: Usar dataflow pero asegurandose que de no haya caminos incorrectos
- **Cómo?**
 - **Inlining:** Incluir el código del método llamado dentro del llamador.
 - Mirar el programa como un único procedimiento monolítico
 - Instanciar parametros de entrada y salida
 - **Clonning:** Crear una copia del método para cada llamada
 - Cada copia del método representa un contexto diferente

Inlining/Cloning

```
int divByX(int x) {
    [result := 10/x]₁;
}

void caller1() {
    [x := 5]₁;
    [y := divByX(x)]₂;
    [y := divByX(5)]₃;
    [y := divByX(0)]₄;
}
```

Cloning

```
void caller1() {
    [x := 5]₁;
    [y := divByX_1(x)]₂;
    [y := divByX_2(5)]₃;
    [y := divByX_3(0)]₄;
}

int divByX_1(int x) {
    [result := 10/x]₁;
}

int divByX_2(int x) {
    [result := 10/x]₁;
}

int divByX_3(int x) {
    [result := 10/x]₁;
}
```

Inlining

```
void caller1() {
    [x := 5]₁;
    [y := divByX(x)]₂;
    y := 10/x;
    [y := divByX(5)]₃;
    y := 10/5;
    [y := divByX(0)]₄;
    y := 10/0;
}
```

•Ventajas:

- Mayor precisión
 - Una versión del método para cada contexto

•Desventajas

- Mayor costo computacional
 - Explosión de código

Problemas Inlining / Cloning

■ Uso de interfaces

```
Interface I
{
    int getValue();
}
Class A implements I...
Class B implements I...

void process() {
    I i = null;
    if(...)
        i = new A();
    else
        i = new B();

    i.getValue();
}
```

```
Interface I
{
    int getValue();
}

void process(I i) {
    i.getValue();
}
```

■ Recursión

```
void process(int v, int x) {
    if(v==0) return x;
    else return process(v-1,x*v)
}
```

Sensibilidad al contexto

- Hay que distinguir entre los diferentes contextos de llamada a una función
- Varias técnicas
 - Cadenas de llamadas
 - Inlining/Cloning
 - **Asumir / Verificar**
 - Resúmenes por métodos

Asumir/Verificar

- Idea: anotar el método con información sobre pde y lo que se espera el método
 - **Precondición:** Valores iniciales para todos los parámetros
 - **Postcondición:** Un valor al retorno (result)
 - Basadas en el conocimiento del programdor
 - Conocimiento individual sobre cada método.
 - O por "default"
 - Ejemplo: todos los equals
- Verificación
 - En el método anotado
 - Asumir valores para parámetros
 - Verificar en el método anotado que $\text{resultado calculado} \subseteq \text{asumido}_{\text{result}}$
 - En el método llamador
 - Verificar que $\text{arg} \subseteq \text{asumido}_{\text{arg}}$
 - Parámetros actuales cumplen con lo asumido para parámetros formales
 - Usar el valor anotado para result.

Ejemplo

```
@NZ int divByX(@NZ int x)
{
    [result := 10/x]₁;
}

void caller1() {
    [x := 5]₁;
    [y := divByX(x)]₂;
}
```

■ Análisis de divByX

pos	x	Result
0	NZ	\perp
1	NZ	NZ

- Cumple que $\sigma(\text{result}) \subseteq \text{NZ}$

■ Análisis de caller1

pos	x	y
0	\perp	\perp
1	NZ	\perp

- Verifica que $\sigma(x) \subseteq \text{NZ}$

Ejemplo

```
@NZ int doble(@NZ int x)
{
    [result := 2*x]1;
}
```

```
void caller1() {
    [x := 0]1;
    [y := doble(x)]2;
}
```

■ Análisis de doble

pos	x	Result
0	NZ	\perp
1	NZ	NZ

- Cumple que $\sigma(\text{result}) \subseteq \text{NZ}$

■ Análisis de caller 1

pos	x	y
0	\perp	\perp
1	Z	\perp

- $\sigma(x) \subseteq \text{NZ}$ falla!
- No cumple con la precondition asumida
- Es un falso positivo aunque el programa esté OK.

Ejemplo

```
@MZ int doble(@MZ int x)
{
    [result := 2*x]1;
}
```

```
void caller1() {
    [x := 5]1;
    [y := doble(x)]2;
    [z := 10/y]3;
}
```

■ Análisis de doble

pos	x	Result
0	MZ	\perp
1	MZ	MZ

- Cumple que $\sigma(\text{result}) \subseteq \text{MZ}$

■ Análisis de caller 1

pos	x	y	z
0	\perp	\perp	\perp
1	NZ	\perp	\perp

- Verifica $\sigma(x) \subseteq \text{MZ}$
- Warning: div por cero!
- Es un falso positivo!

Sensibilidad al contexto

- Hay que distinguir entre los diferentes contextos de llamada a una función
- Varias técnicas
 - Cadenas de llamadas
 - Inlining/Cloning
 - Asumir/Verificar
 - **Resúmenes por métodos**

Resúmenes sentivos a contexto

- Idea:
 - Calcular un único resumen por cada método
 - Mapear información dataflow de entrada en información dataflow de salida
- Sensitivos a contexto
 - Dan diferentes resultados para diferentes entradas
 - Instanciar el resumen en el momento de la llamada

Generando Resúmenes S a C

- Fuerza bruta
 - Analizar la función para cada posible valor de entrada
 - No escala porque los reticulados de los parámetros pueden ser enormes!
- Bajo demanda
 - Analizar la función para cada valor que pueden tomar los parámetros, mirando las todas las llamadas en el código
 - Mejor pero aún impracticable
- Resúmenes abstractos
 - Representar de forma simbólica el efecto de la función sobre los elementos de los reticulados de los parámetros
 - Esto es lo que se hace en los análisis actuales

Resúmenes bajo demanda

- Case $x:NZ \rightarrow \text{result}:NZ$
- Case $x:Z \rightarrow \text{result}:Z$

```
int doble(int x) {
    [result := 2*x]1;
}

void caller1() {
    [x := 5]1;
    [y := doble(x)]2;
    [z := 10/y]3;
    [x := 0]4;
    [y := doble(x)]5;
}
```

doble: caso $x:NZ \rightarrow \text{result}:NZ$

pos	x	Result
0	NZ	\perp
1	NZ	NZ

■ Análisis de caller 1

pos	x	Y	Z
0	\perp	\perp	\perp
1	NZ	\perp	\perp
3	NZ	NZ	NZ
4	Z	NZ	NZ

doble: caso $x:Z \rightarrow \text{result}:Z$

pos	x	Result
0	Z	\perp
1	Z	Z

Anotaciones sensibles a contexto

```
@Case("x:NZ -> result:NZ")
@Case("x:Z -> result:Z")
int doble(int x) {
    [result := 2*x]1;
}

void caller1() {
    [x := 5]1;
    [y := doble(x)]2;
    [z := 10/y]3;
    [x := 0]4;
    [y := doble(x)]5;
}
```

- Verifico en caller 1
- Caso $x:NZ$

Pos	x	y	Z
1	NZ	\perp	\perp

- Verifico caller 1
- Caso $x:Z$

4	Z	NZ	NZ
---	---	----	----

Verifico : caso $x:NZ \rightarrow \text{result}:NZ$

pos	x	Result
0	NZ	\perp
1	NZ	NZ

verifico: caso $x:Z \rightarrow \text{result}:Z$

pos	x	Result
0	Z	\perp
1	Z	Z

Resúmenes abstractos

Resumen:
Case $x:A \rightarrow \text{result}:A$

```
int doble(int x) {
    [result := 2*x]1;
}

void caller1() {
    [x := 5]1;
    [y := doble(x)]2;
    [z := 10/y]3;
    [x := 0]4;
    [y := doble(x)]5;
}
```

■ Análisis de caller 1

pos	x	y	Z
0	\perp	\perp	\perp
1	NZ	\perp	\perp
3	NZ	NZ	NZ
4	Z	NZ	NZ

A=NZ

A=Z

doble:

pos	x	Result
0	A	\perp
1	A	A

Calculando resúmenes


- Se recorre el call graph de la aplicación de forma Bottom-Up
 - Empezando por las hojas se asegura que no hay métodos a llamar
 - Realizar un análisis intraprocedural
 - Guardar resumen
 - Cuando un método llama a otro
 - Buscar resumen (esta por recorrido bottom up)
 - Instanciarlo con argumentos (top down)
- Para métodos recursivos requiere otro punto fijo
 - Sobre el subcomponente recursiva
 - Ciclo en el Call Graph

Call Graph

- Un “mapa” para saber que métodos analizar
 - Fundamental en programas orientados a objetos

```
static void main() {  
    B b1 = new B();  
    A a1 = new A();  
    f(b1);  
    g(b1);  
}  
static void f(A a2) {  
    a2.foo();  
}  
static void g(B b2) {  
    B b3 = b2;  
    b3 = new C();  
    b3.foo();  
}
```

```
class A {  
    foo() {..}  
}  
class B extends A {  
    foo() {...}  
}  
class C extends B {  
    foo() {...}  
}  
class D extends B {  
    foo() {...}  
}
```




Call Graph

- Un “mapa” para saber que métodos analizar
 - Fundamental en programas orientados a objetos

```
static void main() {  
    B b1 = new B();  
    A a1 = new A();  
    f(b1);  
    g(b1);  
}  
static void f(A a2) {  
    a2.foo();  
}  
static void g(B b2) {  
    B b3 = b2;  
    b3 = new C();  
    b3.foo();  
}
```

```
class A {  
    foo() {..}  
}  
class B extends A {  
    foo() {...}  
}  
class C extends B {  
    foo() {...}  
}  
class D extends B {  
    foo() {...}  
}
```




Calculado usando Class Hierarchy Analysis (CHA)

Call Graph

- Un “mapa” para saber que métodos analizar
 - Fundamental en programas orientados a objetos

```
static void main() {  
    B b1 = new B();  
    A a1 = new A();  
    f(b1);  
    g(b1);  
}  
static void f(A a2) {  
    a2.foo();  
}  
static void g(B b2) {  
    B b3 = b2;  
    b3 = new C();  
    b3.foo();  
}
```

```
class A {  
    foo() {..}  
}  
class B extends A {  
    foo() {...}  
}  
class C extends B {  
    foo() {...}  
}  
class D extends B {  
    foo() {...}  
}
```




Calculado usando Rapid Type Analysis (RTA)

Call Graph

- Un “mapa” para saber que métodos analizar
 - Fundamental en programas orientados a objetos

```
static void main(){
  B b1 = new B();
  A a1 = new A();
  f(b1);
  g(b1);
}
static void f(A a2){
  a2.foo();
}
static void g(B b2){
  B b3 = b2;
  b3 = new C();
  b3.foo();
}
```

```
class A {
  foo() {...}
}
class B extends A{
  foo() {...}
}
class C extends B{
  foo() {...}
}
```



Calculado usando XTA

Sentividad a flujo vs. contexto

- Lo más preciso es ser sensitivo a ambos
- Pero si tuvieran que sacrificar sensitividad cual elegirían?
 - Flujo?
 - Contexto?
- En lenguajes OO se suele sacrificar flujo pero no contexto
 - Se asume que los métodos son cortos

Conclusiones

- Asunciones
 - Simple y eficiente
 - Impreciso (muy generales)
- Anotaciones
 - Requiere cierto esfuerzo
 - Suelen ser más precisas que las asunciones
 - Más eficiente que hacer un análisis interprocedural
- No requieren realizar un análisis de todo el programa!
- Interprocedural CFG
 - Fácil de implementar
 - Es impreciso
 - Puede ser costoso
 - As precise as simple
- Resúmenes
 - Muy precisos
 - Muy costosos si no se realiza una abstracción
- Requieren realizar un análisis de todo el programa

Bibliografía

- Compilers: Principles, Techniques & Tools 2nd Edition: Aho, Lam, Sethi, Ullman
- Principles of Program Analysis. Flemming Nielson, Hanne Riis Nielson, Chris Hankin.
- Modern compiler implementation in Java. Andrew Appel. 2nd Edition.
- Cursos relacionados
 - Aldrich, Aiken, Palsberg, etc.

