

Trabajo Práctico 1


Análisis Dataflow - Points-to analysis

El objetivo del trabajo práctico es desarrollar un análisis de pointst-to para Java utilizando el framework de Dataflow de soot. Para ello deberán primero desarrollar una versión intra-procedural, para luego extender el análisis a varios procedimientos.

Para implementar en análisis utilizaremos un points-to graph (PTG) definido de la siguiente manera: $\mathbf{G} = \langle \mathbf{L}, \mathbf{N}, \mathbf{E}, \mathbf{W} \rangle$ donde

- **N** representa los objetos creados por el programa. Cada nodo representa todos los objetos creados en una sentencia **new**. Es decir, se creará un solo nodo incluso si el new se produce dentro de un ciclo.
- **L**: Local $\rightarrow P(N)$ es un map de variables locales a nodos. Representa los objetos a los que puede apuntar cada variable local.
- **E** es un conjunto de ejes. Un eje $(n1, f, n2)$ indica que un nodo $n1$ (representando un conjunto de objetos) apunta a otro nodo $n2$, mediante el campo f .
- **W** es un conjunto de sentencias: representa los puntos donde el análisis tuvo problemas (ver punto 1)

Graficamente, un $\text{PTG} = \langle [a \leftarrow \{C\}, b \leftarrow B2, c \leftarrow C, d \leftarrow B5, e \leftarrow B5], \{ (A, f, B2), (C, f, B5) \}, \{A, B2, B5, C\} \rangle$ luce de la siguiente forma:



El PTG debe ser utilizado como un reticulado por lo que hay que definir sus operaciones básicas:

- $\perp = \langle L, \{\}, \{\} \rangle$ con $L(x) = \{\}$ para toda variable local
- $G1 \subseteq G2$ si $L1 \subseteq L2$ ó $(L1 = L2 \text{ y } N1 \subseteq N2)$ ó $(L1 = L2 \text{ y } N1 = N2 \text{ y } E1 \subseteq E2)$
- $G1 \cup G2 = \langle L1 \cup L2, N1 \cup N2, E1 \cup E2 \rangle$

Utilizaremos un lenguaje Java hiper simplificado. Las reglas Dataflow para el análisis son las siguientes:

| Sentencia | Efecto |
|------------------------------|--|
| p: x = new A() | $G' = G$ con $L'(x) = \{A_p\}$ |
| x = y | $G' = G$ con $L'(x) = L(y)$ |
| x = y.f | $G' = G$ con $L'(x) = \{ n \mid (a,f,n) \in E \text{ forall } a \in L(y) \}$ |
| x.f = y | $G' = G$ con $E' = E \cup \{ (a,f,n) \mid n \in L(y) \ \&\& \ a \in L(x) \}$ |
| ret = a0.m(a1,...,an) | Ver parte interprocedural |

Pueden asumir que no hay variables globales.

Parte 1: Análisis intraprocedural

- 1) Desarrollar un análisis intraprocedural siguiendo las reglas mencionadas en la tabla. En el caso de llamadas a métodos, no analizarlas pero incluir la sentencia en el conjunto W (no analizables).
- 2) Extender el análisis intraprocedural de forma tal que pueda distinguir “lecturas” de “escrituras” y soportar parámetros. Para ello se debe incluir un nuevo tipo de nodo que represente a cada uno de los parámetros del método (parameter nodes). Estos deben ser ligados a los parámetros del método al comienzo de la ejecución del mismo ($L(p)=\{PN\}$ para todo p). Además agregaremos un nuevo tipo de nodo llamado load node (ln) y un nuevo tipo de ejes de la forma (n,f,ln) (conjunto R de ejes). Las nuevas reglas son las siguientes:

| Sentencia | Efecto |
|------------------------------|---|
| p: x = new A() | $G' = G$ con $L'(x) = \{A_p\}$ |
| x = y | $G' = G$ con $L'(x) = L(y)$ |
| x = y.f | $G' = G$ con $R' = R \cup \{ (n,f,ln) \mid n \in L(y) \}$ y $L'(x) = \{ ln \}$ con ln fresco |
| x.f = y | $G' = G$ con $E' = E \cup \{ (a,f,n) \mid n \in L(y) \ \&\& \ a \in L(x) \}$ |
| ret = a0.m(a1,...,an) | Ver parte interprocedural |

Parte 2: Análisis interprocedural

- 3) Realizar un análisis interprocedural del ejercicio 1 utilizando la técnica del **CFG interprocedural**. Es decir conectando de forma adecuada los diferentes CFG de los métodos del programa bajo análisis
- 4) Realizar un análisis interprocedural simulando la técnica de **inlining**. Es decir, utilizando un solo PTG global, pero cada vez que se realiza una llamada a un método, simular que el método llamado es parte del método original. Para ello deben realizar el correcto *binding* de parámetros de entrada y salida. En el caso de recursión pueden incluir el método en el conjunto de no analizables.
- 5) Utilizar el resultado del análisis para mostrar el grafo de llamadas del programa analizado.
- 6) (opcional) Extender el análisis utilizando la técnica de **call strings** o **K-limiting**, limitando el contexto de llamada a **K** métodos (un valor que pueda ser configurable). Para implementar esta técnica se puede tanto la idea de limitar los caminos disponibles en el CFG interprocedural o también se puede simular este efecto.
Por ejemplo, se podría guardar un diccionario de call string a la información de Dataflow de cada método. De esta forma se podría recuperar bajo demanda la información de Dataflow de un método para un determinado contexto (dado por el call string) y calcular a partir de esa información utilizando el algoritmo intraprocedural.
- 7) (super-opcional) Realizar una versión **interprocedural** utilizando resúmenes. Los resúmenes tendrán la información de points-to al final del método (borrando la información de variables locales). Para ello se debe incluir un nuevo tipo de nodo que represente a cada uno de los parámetros del método. Luego a la hora de realizar el call se deben “pegar” el PTG del llamador con el del llamado. Esto se logra tomando el resumen del llamado y fusionando los nodos que representan los parámetros con los nodos que representan a los argumentos del llamador. De esta manera, el PTG del llamador al final del call tendrá la información de points-to del método llamado.

Observación: Para el análisis interprocedural van a tener que decidir qué método (de qué clase) es llamado en una invocación. Para eso tienen que usar el mismo análisis de points-to que están calculando.

Observación 2: En el análisis interprocedural **no deben analizar las librerías de Java**. Para eso pueden incluir las sentencias con llamadas a funciones de la librería Java en el conjunto **W**.