

Introducción a la Robótica Móvil

Primer cuatrimestre de 2018

Departamento de Computación - FCEyN - UBA

Robótica Probabilística - clase 11

Repaso de probabilidad, Regla de Bayes y filtros Bayesianos

¿Por qué robótica probabilística?

Para realizar una aplicación real con un robot móvil, debemos tratar con incertezas que provienen de distintos factores:

- Los **entornos** donde operan los robots suelen ser dinámicos, parcialmente observables, no estructurados, no determinísticos (i.e. una porquería).
- Los **sensores** introducen otras incertezas, producto de los propios límites en las resoluciones con las que trabajan. Además los sensores están sujetos a ruido que también es impredecible y que perturba las mediciones.
- Los **actuadores** también son imprecisos para moverse. También tenemos ruido en las señales de control, y los mecanismos sufren un desgaste por el uso que es inevitable.
- El **software** que corre en un robot también introduce incertezas ya que utiliza modelos para representar el mundo que son una abstracción y simplificación del mismo. Además, por restricciones de cómputo (ejecución en tiempo real) también se sacrifica precisión en pos de alcanzar un tiempo de respuesta adecuado.

La idea central es contar con una representación explícita de la incerteza usando el cálculo de la Teoría de Probabilidad.

- Percepción = estimación del estado.
- Actuación = optimización de la utilidad de cada acción.

Un breve repaso de Teoría de Probabilidad


Los siguientes axiomas definen la Teoría de Probabilidad que vamos a usar. Si $P(A)$ denota la probabilidad de que la proposición A sea verdadera, entonces:

- 1) $0 \leq P(A) \leq 1$
- 2) $P(\text{True}) = 1$ y $P(\text{False}) = 0$
- 3) $P(A \vee B) = P(A) + P(B) - P(A \wedge B)$

Un breve repaso de Teoría de Probabilidad

Veamos más de cerca el axioma 3:

$$P(A \vee B) = P(A) + P(B) - P(A \wedge B)$$



Un breve repaso de Teoría de Probabilidad

A partir de los axiomas podemos calcular distintas igualdades:

$$P(A \vee \neg A) = P(A) + P(\neg A) - P(A \wedge \neg A)$$

$$P(\textit{True}) = P(A) + P(\neg A) - P(\textit{False})$$

$$1 = P(A) + P(\neg A) - 0$$

$$P(\neg A) = 1 - P(A)$$

Un breve repaso de Teoría de Probabilidad

Sea X una variable aleatoria discreta:

- X puede tomar un valor discreto dentro de x_1, x_2, \dots, x_n .
- $P(X = x_i)$ o $P(x_i)$ es la probabilidad de que la variable X tome el valor x_i .
- $P(\cdot)$ se denomina función de masa de probabilidad (o función de probabilidad).
- $\sum_{x_i} P(x_i) = 1$

Un breve repaso de Teoría de Probabilidad

Sea X una variable aleatoria continua:

- X puede tomar uno valor cualquiera dentro de un intervalo continuo $[a, b]$.
- $p(X = x)$ o $p(x)$ es la probabilidad de que la variable X tome el valor x .
- $p(\cdot)$ se denomina función de densidad de probabilidad (o función de densidad):

$$P(X \in [a, b]) = \int_a^b p(x)dx$$

- $\int_{-\infty}^{\infty} p(x)dx = 1$

Un breve repaso de Teoría de Probabilidad

Sea X una variable aleatoria continua:

- $F(\cdot)$ se denomina función de distribución de probabilidad (o función de distribución):

$$F_X(a) = P(X \leq a) = \int_{-\infty}^a p(x)dx$$

- $F(\cdot)$ cumple que:

$$\lim_{x \rightarrow -\infty} F(x) = 0 \quad \lim_{x \rightarrow \infty} F(x) = 1$$

- Podemos usar la función de distribución para hallar la probabilidad de que $X \in [a, b]$

$$P(X \in [a, b]) = F(b) - F(a)$$

Un breve repaso de Teoría de Probabilidad

Sean X e Y dos variables aleatorias, entonces:

- $P(X = x \text{ y } Y = y) = P(x, y) = P(y, x)$ se llama probabilidad conjunta.
- Si X e Y son independientes $P(x, y) = P(x)P(y)$.
- $P(x|y)$ es la probabilidad de x dado y o probabilidad condicional:

$$P(x|y) = P(x, y)/P(y) \quad (\text{si } P(y) > 0)$$


$$P(x, y) = P(x|y)P(y)$$

- Si X e Y son independientes
 $P(x|y) = P(x, y)/P(y) = P(x)P(y)/P(y) = P(x)$

Un breve repaso de Teoría de Probabilidad

El Teorema de la Probabilidad Total nos dice que:

- $P(x) = \sum_y P(x|y)P(y)$ para el caso discreto.
- $p(x) = \int p(x|y)p(y)dy$ para el caso continuo.



El Teorema de la Probabilidad Marginal nos dice que:

- $P(x) = \sum_y P(x, y)$ para el caso discreto.
- $p(x) = \int p(x, y)dy$ para el caso continuo.

El Teorema de Bayes



Thomas Bayes, 1702-1761.

El Teorema de Bayes nos dice que:

- $P(x, y) = P(y, x)$ por definición de probabilidad conjunta.
- $P(x, y) = P(x|y)P(y) = P(y|x)P(x)$ por definición de probabilidad condicional.
- Luego, despejando tenemos que:

$$P(x|y) = P(y|x)P(x)/P(y)$$

El problema de la Localización

Es la habilidad que posee un robot de localizarse en el espacio por sí sólo.


- Es uno de los problemas centrales de la robótica móvil.
- En general, no puede ser resuelto con un sólo (tipo de) sensor.
- Es mejor si utilizamos un enfoque probabilístico para resolver este problema.

Ejemplo de localización

- Tenemos un robot en un mundo de una dimensión.
- El robot se puede mover sólo hacia delante o hacia atrás.
- Tenemos un mapa completo del mundo, pero no sabemos dónde está el robot.
- En el mundo hay tres puertas (**landmarks**), el robot puede detectar si se encuentra al lado de una puerta o no.


Ejemplo: Posición inicial

- Como en un principio el robot desconoce cual es su posición entonces es igualmente posible que se encuentre en cualquier punto del mundo (eso se llama la creencia del robot, o **belief**).
- Podemos representar esto matemáticamente diciendo que la **función de densidad de probabilidad** del robot es **uniforme** sobre el mundo en que se encuentra.



Ejemplo: Medición


- Si el robot sensa que se encuentra al lado de una puerta entonces la creencia de su ubicación se ve alterada de alguna manera.
- Esta nueva función representa otra distribución de probabilidades llamada **posterior belief**.
- La función de posterior belief es la mejor representación de la posición del robot actualmente. Cada pico representa la evaluación de su posición con respecto a una puerta.



¿Por qué hay tres picos? ¿Por qué no son puntuales?


Ejemplo: Movimiento

- Si ahora el robot se mueve hacia la derecha la creencia cambia de acuerdo al **movimiento**.
- Como el movimiento del robot es inexacto, al trasladarse **la incertidumbre crece**, por lo que los picos se hacen más anchos.
- Este aplanamiento matemáticamente se lleva a cabo por medio de la operación de **convolución** entre la función de posterior belief y la función que describe el movimiento del robot.



Ejemplo: Segunda medición

- Después de haberse movido el robot sensa nuevamente que se encuentre al lado de una puerta
- Entonces, la función de **posterior belief** se incrementara por un cierto factor que es la función de probabilidad de que hayamos sensado una puerta dado que estamos al lado de una puerta.




Ejemplo: Belief luego de sensar

- Un mundo constituido por cinco celdas rojas y verdes $x_{i=1,\dots,5}$
- Tenemos un mapa del mundo: las celdas x_2 y x_3 son rojas, y el resto verdes.
- Inicialmente el robot desconoce su posición.
- La probabilidad de que el robot sense correctamente esta dada por la siguiente distribución de probabilidades:

$$P(\text{sensa } color | x_i = color) = 0,6$$


$$P(\text{sensa } \neg color | x_i = color) = 0,2$$

Observar que esto no es una probabilidad correcta ya que la suma debería ser 1 (pero en robótica nos tomamos esta licencia poética).




Ejemplo: Belief luego de sensar

Si el robot **sensa rojo**, ¿Cuál es su Posterior belief?



Ejemplo: Belief luego de sensar

Si el robot **sensa rojo**, ¿Cuál es su Posterior belief?



$$P(x_i = \text{rojo} | \text{sensa rojo}) = P(\text{sensa rojo} | x_i = \text{rojo})P(x_i) = 0,6 \times 0,2 = 0,12$$

$$P(x_i = \text{verde} | \text{sensa rojo}) = P(\text{sensa rojo} | x_i = \text{verde})P(x_i) = 0,2 \times 0,2 = 0,04$$

Ejemplo: Belief luego de sensar

$$P(x_i = \text{rojo} | \text{sensa rojo}) = 0,12$$

$$P(x_i = \text{verde} | \text{sensa rojo}) = 0,04$$

Observar que la función de probabilidad del posterior belief es incorrecta dado que la suma no da 1:

$$\sum_{i=1}^5 P(x_i) = 0,04 + 0,12 + 0,12 + 0,04 + 0,04 = 0,36$$

Tenemos que normalizar:

$$P(x_i = \text{rojo} | \text{sensa rojo}) = \frac{0,12}{0,36} = \frac{1}{3}$$

$$P(x_i = \text{verde} | \text{sensa rojo}) = \frac{0,04}{0,36} = \frac{1}{9}$$

En general, $P(x_i | z)$ es se conoce como Posterior belief del lugar x_i dada la medición z .

Ejemplo: Regla de Bayes

Cuando el robot sensa no hace otra cosa que aplicar el teorema de Bayes:

$$P(x_i|z) = \frac{P(z|x_i)P(x_i)}{P(z)}$$

$P(x_i|z)$: probabilidad a Posteriori (Posterior Belief) dado que sensé z

$P(z|x_i)$: probabilidad de Medición dado que estoy en x_i

$P(x_i)$: probabilidad a Priori de estar en x_i

$P(z)$: probabilidad de sensar z independientemente de donde esté.

Para hallar $P(z)$ usamos el teorema de la probabilidad total:

$$P(z) = \sum_{x_i} P(z|x_i)P(x_i)$$

Ejemplo: Regla de Bayes

Entonces podemos reescribir la regla de Bayes como:

$$P(x_i|z) = \frac{P(z|x_i)P(x_i)}{P(z)} = \eta P(z|x_i)P(x_i)$$

$$\text{donde } \eta = P(z)^{-1} = \frac{1}{\sum_{x_i} P(z|x_i)P(x_i)}$$

Nota: η es el término de normalización que usamos para que el posterior belief sea una probabilidad bien definida.

Ejemplo: Belief luego del movimiento

Veamos ahora como cambia el belief cuando el robot se mueve:


- Supongamos un mundo **cíclico** constituido por cinco celdas x_i donde $i = 1, \dots, 5$
- La distribución de probabilidad a priori esta determinada por:

$$P(x_1) = P(x_4) = P(x_5) = \frac{1}{9}$$

$$P(x_2) = P(x_3) = \frac{1}{3}$$


Ejemplo: Belief luego del movimiento

Si el robot tiene una **motricidad exacta** y desea moverse 1 celda a la derecha, ¿Cuál es su Posterior belief?



Ejemplo: Belief luego del movimiento

Si el robot tiene una **motricidad exacta** y desea moverse 1 celda a la derecha, ¿Cuál es su Posterior belief?




Ejemplo: Belief luego del movimiento

Suponiendo ahora que el robot desea moverse 2 celdas a la derecha y tiene una **motricidad inexacta** con la siguiente distribución de probabilidad:

$$P(x_{i+1}|x_i) = 0,1$$



$$P(x_{i+2}|x_i) = 0,8$$

$$P(x_{i+3}|x_i) = 0,1$$





Ejemplo: Belief luego del movimiento

Si el robot conoce exactamente cuál es su posición inicial, ¿Cuál es su posterior belief?



Ejemplo: Belief luego del movimiento

Si el robot conoce exactamente cuál es su posición inicial, ¿Cuál es su posterior belief?





Ejemplo: Belief luego del movimiento

Si el robot tiene como distribución inicial que se encuentra en las celdas x_2 y x_4 con igual probabilidad, formalmente,

$$P(x_2) = P(x_4) = 0,5$$

¿Cuál es su Posterior belief?





Ejemplo: Belief luego del movimiento

Si el robot tiene como distribución inicial que se encuentra en las celdas x_2 y x_4 con igual probabilidad, formalmente,

$$P(x_2) = P(x_4) = 0,5$$

¿Cuál es su Posterior belief?



$$P(x_1) = P(x_4)P(x_1|x_4) = 0,5 \times 0,8 = 0,4$$

$$P(x_2) = P(x_4)P(x_2|x_4) = 0,5 \times 0,1 = 0,05$$


$$P(x_3) = P(x_2)P(x_3|x_2) = 0,5 \times 0,1 = 0,05$$

$$P(x_4) = P(x_2)P(x_4|x_2) = 0,5 \times 0,8 = 0,4$$

$$P(x_5) = P(x_2)P(x_5|x_2) + P(x_4)P(x_5|x_4) = 0,5 \times 0,1 + 0,5 \times 0,1 = 0,1$$

Ciclo de sensar y mover

Localización no es más que la iteración de dos procesos probabilísticos:
sensar el entorno y moverse en el entorno:



Dado un conjunto de observaciones y acciones de control del robot para moverse:

$$d_t = \{u_1, z_1, \dots, u_t, z_t\}$$


- El modelo de sensado es $p(z_t|x_t)$
- El modelo de movimiento es $p(x_t|u_t, x_{t-1})$
- La probabilidad a priori del estado del sistema es $p(x_t)$

Lo que queremos es estimar el estado de nuestro sistema a posterior de la acción y del sensado, o el posterior belief

$$bel(x_t) = p(x_t|u_1, z_1 \dots, u_t, z_t)$$

Filtro Bayesiano: asunción de Markov

Para pasar al próximo estado, basta con conocer el estado anterior y la acción que realiza el robot.



$$p(z_t | x_{0:t}, z_{1:t}, u_{1:t}) = p(z_t | x_t)$$
$$p(x_t | x_{0:t-1}, z_{1:t}, u_{1:t}) = p(x_t | x_{t-1}, u_t)$$

Filtro Bayesiano: derivación

$$bel(x_t) = p(x_t | u_1, z_1, \dots, u_t, z_t) = p(x_t | z_{1:t}, u_{1:t})$$

$$\text{(por Bayes)} = \eta p(z_t | x_t, z_{1:t-1}, u_{1:t}) p(x_t | z_{1:t-1}, u_{1:t})$$

$$\text{(por Markov)} = \eta p(z_t | x_t) p(x_t | z_{1:t-1}, u_{1:t})$$

$$\text{(por Prob. Total)} = \eta p(z_t | x_t) \int p(x_t | z_{1:t-1}, u_{1:t}, x_{t-1}) p(x_{t-1} | z_{1:t-1}, u_{1:t}) dx_{t-1}$$

$$\text{(por Markov)} = \eta p(z_t | x_t) \int p(x_t | u_t, x_{t-1}) p(x_{t-1} | z_{1:t-1}, u_{1:t}) dx_{t-1}$$

$$\begin{aligned} \text{(por Markov)} &= \eta p(z_t | x_t) \int p(x_t | u_t, x_{t-1}) p(x_{t-1} | z_{1:t-1}, u_{1:t-1}) dx_{t-1} \\ &= \eta p(z_t | x_t) \int p(x_t | u_t, x_{t-1}) bel(x_{t-1}) dx_{t-1} \end{aligned}$$

Filtro Bayesiano: algoritmo

El algoritmo de bayes recibe el posterior belief del estado anterior y devuelve posterior belief del estado actual:

$$bel(x_t) = \eta p(z_t|x_t) \int p(x_t|u_t, x_{t-1}) bel(x_{t-1}) dx_{t-1}$$


Pseudocódigo del Filtro de Bayes

```
1: for  $x_t$  do  
2:    $\overline{bel}(x_t) = \int p(x_t|u_t, x_{t-1}) bel(x_{t-1}) dx_{t-1}$   
3:    $bel(x_t) = \eta p(z_t|x_t) \overline{bel}(x_t)$   
4: end for  
5: return  $bel(x_t)$ 
```

donde η es el término de normalización y $\overline{bel}(x_t)$ es el prior belief del estado x_t , i.e. la *predicción* del estado x_t antes de la *medición* z_t .

¿Cómo calculamos el integral recorriendo todos los estados?
¿Cuáles son las funciones de densidad de probabilidad?

En la próxima clase...



Más sobre Filtros Bayesianos, Filtro de Kalman y Filtro Extendido de Kalman!