

# Introducción a la Robótica Móvil

Primer cuatrimestre de 2018

Departamento de Computación - FCEyN - UBA

Mapeo del entorno (*mapping*) - clase 17

Mapeo utilizando grillas de ocupación (*occupancy grids*)

# ¿Por qué construir mapas del entorno?

- No siempre tenemos una representación del espacio de trabajo del robot.
- Construir mapas del ambiente (mapeo) es uno de los problemas fundamentales de la robótica.
- Sin un mapa es imposible que el robot pueda llevar adelante su tarea, no puede localizarse, no puede planificar trayectorias seguras.
- Contra más preciso sea el mapa, mejor va a ser el desempeño del robot.
- Mapear y localizarse es como resolver el problema del huevo y la gallina. El mapeo involucra simultáneamente estimar la pose del robot en el mapa.
- Por eso generalmente se deben abordar ambos problemas (mapear y localizarse) al mismo tiempo, lo que se conoce SLAM (*Simultaneous Localization and Mapping*).
- Para comenzar a tratar el problema del mapeo vamos a considerar que la pose del robot es conocida.

# ¿Qué problemas tenemos que enfrentar?

- La interpretación (o modelo) del sensor
  - ¿Cómo extraemos información relevante de los datos crudos que nos arroja el sensor.
  - ¿Cómo representamos e integramos esta información a lo largo del tiempo?
- Las ubicaciones del robot tienen que ser estimadas (o conocidas)
  - ¿Cómo podemos identificar que el robot se encuentra en un lugar que ya visitó? (*loop closure*)
  - ¿Cómo asociamos los datos para poder saber esto? (*data association*)


# Representación y modelo del entorno

- Representación del entorno
  - Métrica y continua  $\rightarrow x, y, \phi$
  - Métrica y discreta  $\rightarrow$  grilla métrica
  - Topológica y discreta  $\rightarrow$  grilla topológica
- Modelo (mapa) del entorno
  - Datos crudos del sensor: usamos toda la información capturada, grandes volúmenes de datos, poca distintividad
  - Características de bajo nivel: por ejemplo características geométricas simples, volumen de datos medio, media distintividad, se puede filtrar la información inútil, pero continúan ambigüedades
  - Características de alto nivel: por ejemplo características visuales, reconocimiento de objetos, poco volumen de datos, alta distintividad.

Tenemos que elegir el tipo apropiado de mapa (modelo) de acuerdo con la tarea que queremos resolver.


# Representación métrica discreta

Descomposición en forma de una grilla de celdas de tamaño fijo.



# Grillas de ocupación (*occupancy grids*)

- Introducido por Moravec y Elfes en 1985.
- Dadas las limitaciones intrínsecas de cualquier sensor, es importante componer un modelo del mundo coherente usando la información capturada en múltiples sensados.
- Se representa el entorno con una una grilla de celdas de tamaño fijo.
- Se estima la probabilidad de que cada celda esté ocupada por un obstáculo.
- Se asumen dos hipótesis muy importantes:



- 1 La probabilidad (o *belief*) de ocupación de cada celda ( $m[x, y]$ ) es independiente:

$$Bel(m_t) = p(m_t | u_1, z_1, \dots, u_{t-1}, z_t) = \prod_{x,y} Bel(m_t^{[x,y]})$$

Por lo tanto podemos calcularla de forma independiente para cada celda.

- 2 ¡La pose del robot es conocida!

# Repaso: Regla de Bayes

Cuando el robot sensa no hace otra cosa que aplicar el teorema de Bayes:

$$P(x|z) = \frac{P(z|x)P(x)}{P(z)}$$

$P(x|z)$  : probabilidad a posteriori (*posterior belief*) dado que sensé  $z$

$P(z|x)$  : probabilidad de medición dado que estoy en  $x$

$P(x)$  : probabilidad a priori de estar en  $x$

$P(z)$  : probabilidad de sensar  $z$  independientemente de donde esté.

Para hallar  $P(z)$  usamos el teorema de la probabilidad total:

$$P(z) = \sum_x P(z|x)P(x)$$

Entonces podemos reescribir la regla de Bayes como:

$$P(x|z) = \frac{P(z|x)P(x)}{P(z)} = \eta P(z|x)P(x)$$

$$\text{donde } \eta = P(z)^{-1} = \frac{1}{\sum_x P(z|x)P(x)}$$

**Nota:**  $\eta$  es el término de normalización que usamos para que el posterior belief sea una probabilidad bien definida.

Dado un conjunto de observaciones y acciones de control del robot para moverse:

$$d_t = \{u_1, z_1, \dots, u_t, z_t\}$$

- El modelo de sensado es  $p(z_t|x_t)$
- El modelo de movimiento es  $p(x_t|u_t, x_{t-1})$
- La probabilidad a priori del estado del sistema es  $p(x_t)$

Lo que queremos es estimar el estado de nuestro sistema a posterior de la acción y del sensado, i.e., la probabilidad condicional a posterior es el *posterior belief*

$$Bel(x_t) = p(x_t|u_1, z_1, \dots, u_t, z_t)$$



# Repaso: Filtro Bayesiano

$$Bel(x_t) = p(x_t | u_1, z_1 \dots, u_t, z_t) = p(x_t | z_{1:t}, u_{1:t})$$

$$\text{(por Bayes)} = \eta p(z_t | x_t, z_{1:t-1}, u_{1:t}) p(x_t | z_{1:t-1}, u_{1:t})$$

$$\text{(por Markov)} = \eta p(z_t | x_t) p(x_t | z_{1:t-1}, u_{1:t})$$

$$\text{(por Prob. Total)} = \eta p(z_t | x_t) \int p(x_t | z_{1:t-1}, u_{1:t}, x_{t-1}) p(x_{t-1} | z_{1:t-1}, u_{1:t}) dx_{t-1}$$

$$\text{(por Markov)} = \eta p(z_t | x_t) \int p(x_t | u_t, x_{t-1}) p(x_{t-1} | z_{1:t-1}, u_{1:t}) dx_{t-1}$$

$$\begin{aligned} \text{(por Markov)} &= \eta p(z_t | x_t) \int p(x_t | u_t, x_{t-1}) p(x_{t-1} | z_{1:t-1}, u_{1:t-1}) dx_{t-1} \\ &= \eta p(z_t | x_t) \int p(x_t | u_t, x_{t-1}) Bel(x_{t-1}) dx_{t-1} \end{aligned}$$

**Idea:** actualizar cada celda usando el Filtro de Bayes. La variable aleatoria  $x$  va a ser cada posición del mapa  $m^{[x,y]}$ :

$$Bel(m_t^{[x,y]}) = \eta p(z_t | m_t^{[x,y]}) \int p(m_t^{[x,y]} | u_t, m_{t-1}^{[x,y]}) Bel(m_{t-1}^{[x,y]}) dm_{t-1}^{[x,y]}$$

**Hipótesis adicional:** el mapa es estático. Entonces nos queda:

$$Bel(m_t^{[x,y]}) = \eta p(z_t | m_t^{[x,y]}) Bel(m_{t-1}^{[x,y]})$$

También nos queda recordando la definición primera:

$$Bel(m_t^{[x,y]}) = p(m_t^{[x,y]} | z_{1:t}, u_{1:t}) = p(m_t^{[x,y]} | z_{1:t})$$

Vamos a discretizar el mapa en celdas de tamaño fijo:

- La proposición  $oc(i, j)$  significa que la celda  $C_{i,j}$  está ocupada
- **Probabilidad:**  $p(oc(i, j))$  tiene rango  $[0, 1]$ .
- **Odds:**  $o(oc(i, j))$  tiene rango  $[0, +\infty)$

$$o(A) = \frac{p(A)}{p(\neg A)}$$

- **Logaritmo de odds:**  $\log o(oc(i, j))$  tiene rango  $(-\infty, +\infty)$
- Cada celda  $C_{i,j}$  va a mantener el valor de  $\log o(oc(i, j))$  en lugar de mantener directamente el valor  $oc(i, j)$ .

- Aplicamos la regla de Bayes:

$$P(x|z) = \frac{p(z|x)p(x)}{p(z)}$$

- donde  $x$  es  $oc(i, j)$  y  $z$  es una observación  $r = D$ .
- Sabemos que  $Bel(m_t^{[x,y]}) = p(m_t^{[x,y]}|z_{1:t}, u_{1:t}) = p(m_t^{[x,y]}|z_{1:t})$ ,
- Si llamamos  $\eta = P(z)^{-1}$ ,  $p(z_t|m_t^{[x,y]}) = P(z|x)$  y  $Bel(m_{t-1}^{[x,y]}) = P(x)$  nos queda:

$$Bel(m_t^{[x,y]}) = \eta p(z_t|m_t^{[x,y]}) Bel(m_{t-1}^{[x,y]})$$

- Podemos simplificar esto usando la representación de *log odds*.

# Grillas de ocupación: deducción

- Regla de Bayes:

$$p(x|z) = \frac{p(z|x)p(x)}{p(z)}$$

- De igual forma:

$$p(\neg x|z) = \frac{p(z|\neg x)p(\neg x)}{p(z)}$$

- Luego:

$$o(x|z) = \frac{p(x|z)}{p(\neg x|z)} = \frac{p(z|x)p(x)}{p(z|\neg x)p(\neg x)} = \lambda(z|x)o(x)$$

- donde:

$$o(x|z) = \frac{p(x|z)}{p(\neg x|z)}$$

$$\lambda(z|x) = \frac{p(z|x)}{p(z|\neg x)}$$

- La Regla de Bayes puede ser reescrita:

$$o(x|z) = \lambda(z|x)o(x)$$

- Tomando *log odds* hacemos que las multiplicaciones sean sumas:

$$\log o(x|z) = \log \lambda(x|z) + \log o(x)$$

- De esta forma tenemos una forma sencilla de actualizar el contenido de la celda.

# Grillas de ocupación: Actualización de cada celda

- Cada celda  $C_{i,j}$  mantiene  $\log o(oc(i,j))$
- La evidencia  $r = D$  significa que el sensado  $r$  retornó  $D$
- Para cada celda  $C_{i,j}$  se acumula la evidencia de cada lectura del sensor:

$$\log o(x|z) = \log \lambda(z|x) + \log o(x)$$
$$\log o(oc(i,j)|r = D) = \log \lambda(r = D|oc(i,j)) + \log o(oc(i,j))$$

- Esta última ecuación es la regla de actualización de cada celda  $C_{i,j}$
- Falta dar el modelo de sensado para poder calcular  $\lambda(r = D|oc(i,j))$ .

El modelo de sensado depende de cada sensor y es un modelo (aproximación) que se propone que debe ajustarse lo más fielmente al comportamiento que tiene el sensor.



La función de probabilidad  $p(z_t|m_t^{[xy]})$  se define como:

$$p(z_t|m_t^{[xy]}) = \frac{1 + model_o^{z_t}(\alpha, d) - model_l^{z_t}(\alpha, d)}{2}$$

Donde:

- $(\alpha, d)$  son las coordenadas polares de la celda  $m_t^{[xy]}$  respecto al marco de referencia del Láser.
- $z_t$  es la distancia medida.


# Modelo de sensado para un Láser 2D

El modelo filtra mediciones más allá de un  $X$ :

$$\blacksquare \text{ model}_o^r(\delta) = \begin{cases} 1 - \left(\frac{\delta-r}{\epsilon}\right)^2, & r < X \wedge \delta \in [r - \epsilon, r + \epsilon] \\ 0, & \text{en otro caso} \end{cases}$$
$$\blacksquare \text{ model}_i^r(\delta) = \begin{cases} 1 - \left(\frac{\delta}{r-\epsilon}\right)^2, & \delta \in [0, r - \epsilon] \\ 0, & \text{en otro caso} \end{cases}$$


Donde:


- $\delta$  es la distancia a considerar por sobre el vector determinado por el haz del láser.



# ¿Cómo obtenemos el mapa de ocupación final?

Entonces el mapa se obtiene considerando que están ocupadas todas las celdas que tienen valor  $C_{i,j} > 0,5$ , que están libres aquellas que tienen valor  $C_{i,j} < 0,5$  y las celdas que tienen valor  $C_{i,j} = 0,5$  son aquellas que sobre las que tenemos información todavía.






- Conectar la celda origen del sensor con la celda correspondiente a donde impactó el láser.
- Definir todas las celdas sobre la línea como desocupadas.
- Definir la celda impactada como ocupada.
- Aplicar la regla de Bayes para actualizar la grilla.
- Utilizar algún algoritmo de gráfico de rectas (Bresenham).
- Mejora: Utilizar algún algoritmo de relleno por difusión (flood fill) para graficar el escaneo láser completo.

# Grillas de ocupación: resumen

- Las grillas de ocupación son un enfoque muy utilizado para representar el entorno de un robot móvil cuando la pose del robot en cada instante es conocida.
- En este enfoque cada celda se considera independientemente del resto.
- Cada celda almacena la probabilidad posterior de que la correspondiente área en el entorno esté ocupada por un obstáculo.
- Las grillas de ocupación pueden ser eficientemente construidas usando un enfoque probabilístico.
- Usando la regla de Bayes y un modelo del sensor podemos obtener una regla de actualización sencilla del contenido de cada celda.
- Para obtener el mapa de mayor verosimilitud utilizamos un umbral (por ejemplo, 0.5)



“Probabilistics Robotics”, Sebastian Thrun, Wolfram Burgard, Dieter Fox. MIT press, 2006. **Capítulo 3**