SIMD

Pack/Unpack

Saturación

Comparación y Máscaras

Organización del Computador II

10 de Abril de 2018

Ezequiel Barrios

Contenido

Brevísimo repaso I

- SSE (Streaming SIMD Extensions) es un set de instrucciones que implementa el **modelo de cómputo SIMD** (una misma instrucción para varios datos a la vez).
- Existen 16 **registros de 128 bits** (XMM0, ..., XMM15)
- Varios posibles **tipos de datos**: **enteros** (8, 16, 32, 64 bits), **flotantes de precisión simple** (32 bits) y **flotantes de precisión doble** (64 bits).
- Distintas **formas de operar**:
  - P = *Packed* (**Empaquetado / Paralelo**).
  - S = *Scalar* (**Escalar**).

Brevísimo repaso II

- Las instrucciones que **comienzan con P** sólo son para operar sobre **enteros** (ejemplo **PADDB**).
- Las instrucciones que comienzan sin *P*, y que **terminan con un determinado sufijo**, son para operar sobre flotantes (ejemplo **ADDPS**). Los sufijos son los siguientes:
  - **SS**: **scalar single**-precision (float)
  - **SD**: **scalar double**-precision (double)
  - **PS**: **packed single**-precision (float)
  - **PD**: **packed double**-precision (double)

Saturación (motivación)

Ejemplo

Escribir una función que aumente el brillo de una imagen en blanco y negro utilizando instrucciones SSE.

Saturación

Ejercicio

Se tiene el brillo de cada píxel de la imagen de entrada en una matriz `IMG` de `N` filas por `M` columnas, y un parámetro `b` entero sin signo según el cual se debe incrementar cada píxel.

```
1    unsigned char IMG[N][M];
2    unsigned char inc;
```

Podríamos hacer:

```
1    for(int i = 0; i < N; i++)
2        for(int j = 0; j < M; j++)
3            IMG[i][j] += inc;
```

¡Cuidado!

¿Qué pasaría si `I[i][j]+b` fuera mayor a 255?

Saturación: incremento de brillo sin saturación

Ejemplo

Tengo un registro con un pixel negro, y le quiero sumar 255.

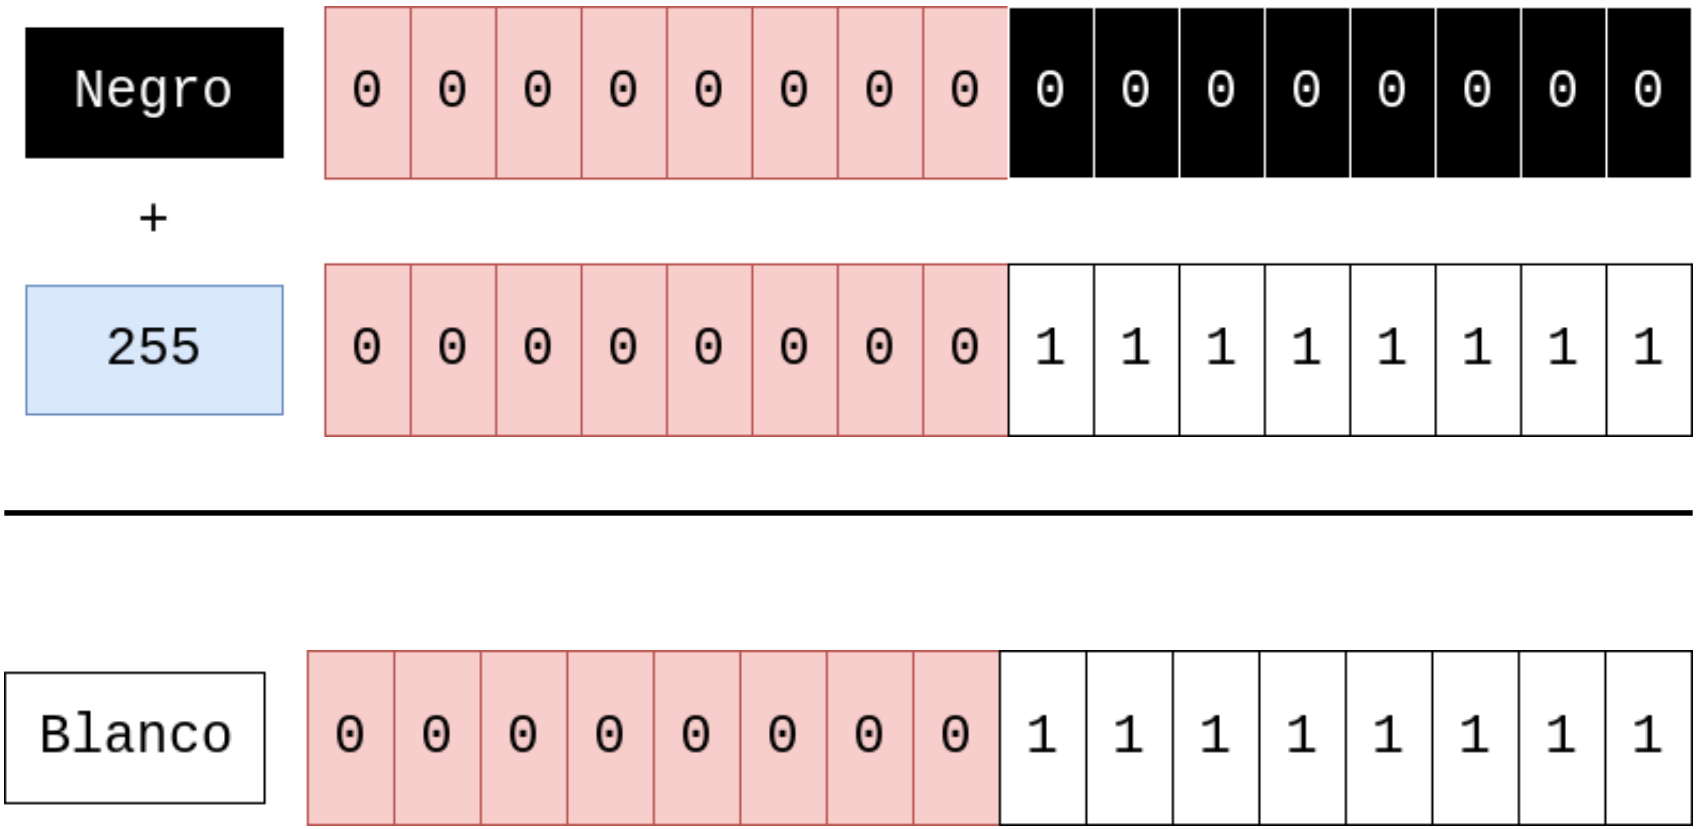

Saturación: incremento de brillo sin saturación

Ejemplo

Tengo un registro con un pixel gris claro, y le quiero sumar 64.

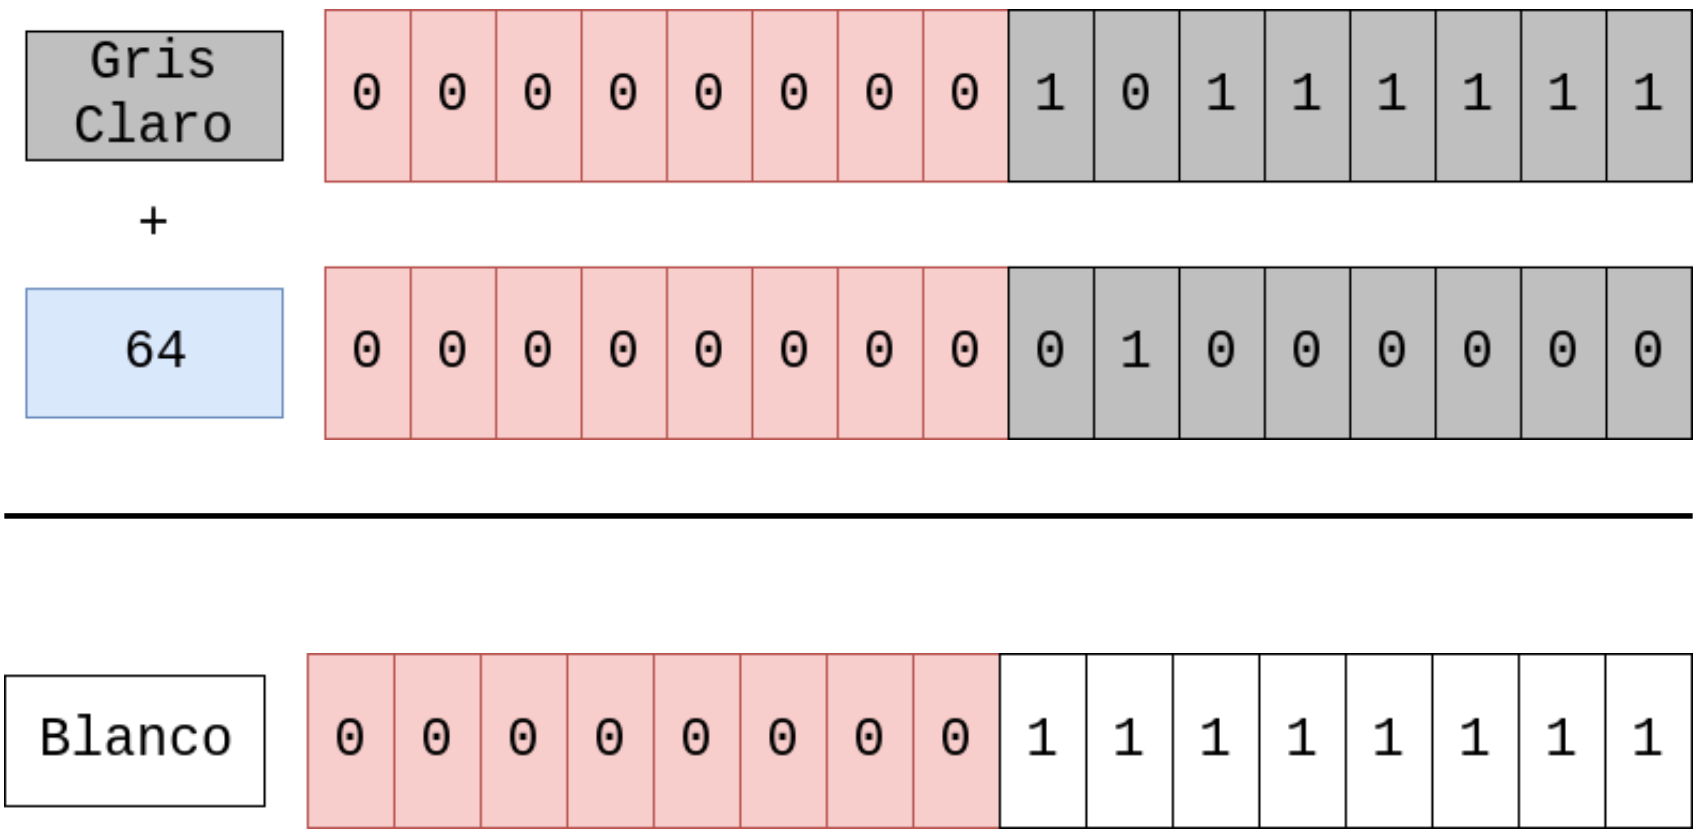

Saturación: incremento de brillo sin saturación

Ejemplo

Tengo el mismo registro anterior, pero le quiero sumar 191.

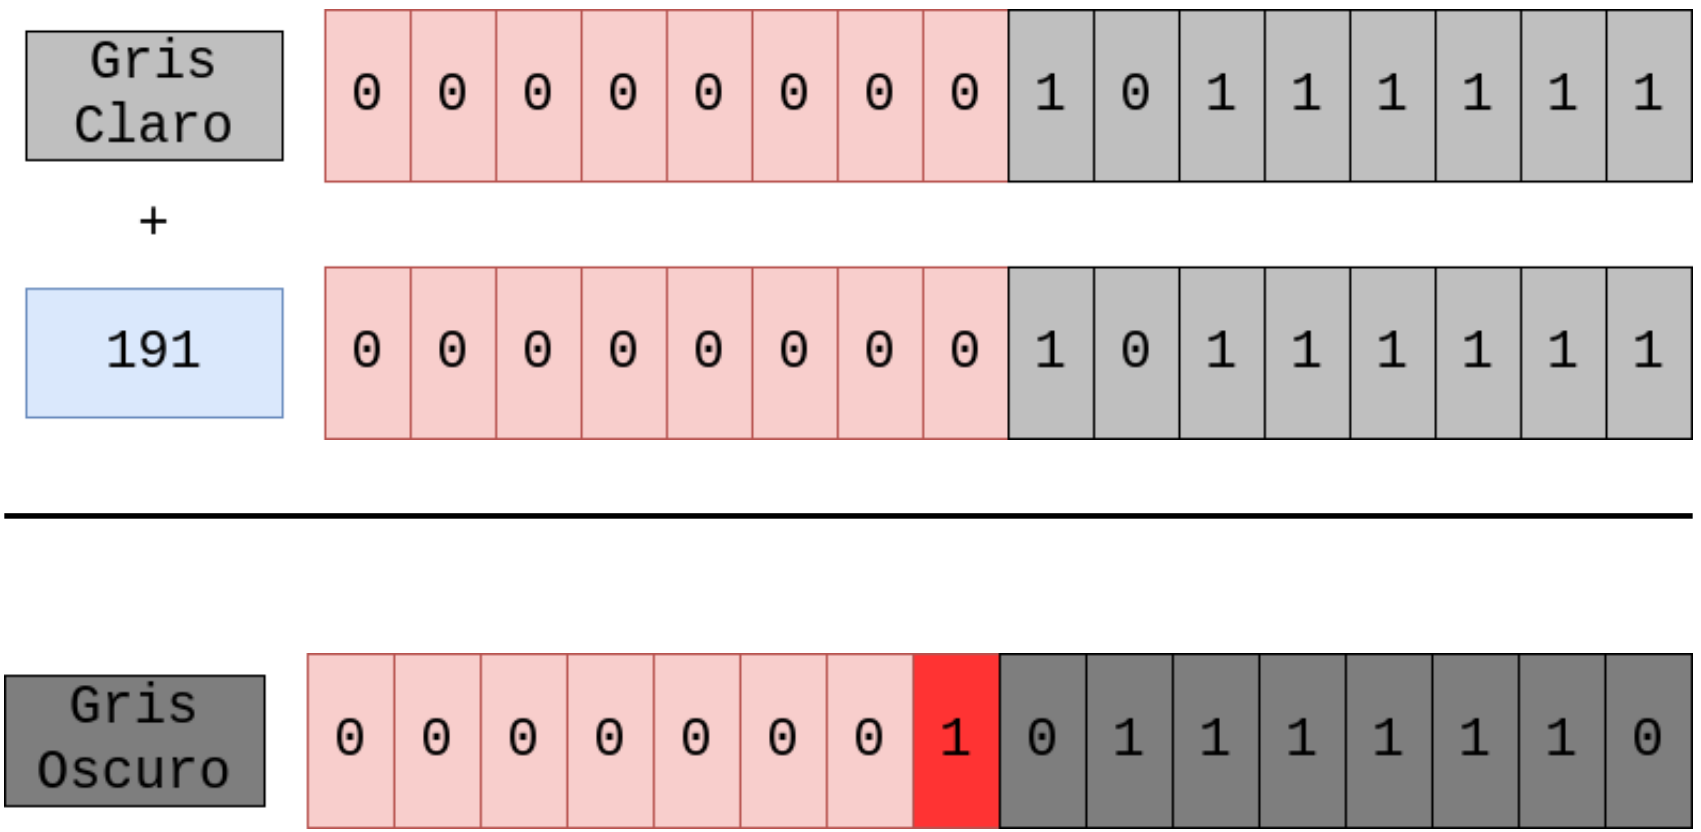

Más ejemplos

(cortesía de ~~nuestra vieja amiga Lena~~ **la Torre de Broadway**)

(a) Original

(b) +50 de brillo

(c) +100 de brillo

(d) +150 de brillo

(e) +200 de brillo

(f) +250 de brillo

(¡La original!)

Saturación: problemas al no saturar

El resultado de la suma podría no entrar en el registro.

- Se trunca el resultado.
- Se pasa de colores más claros (cercanos al 255) a colores más oscuros (cercanos al 0).

Una forma de evitar esto, podría ser:

Incremento de brillo con saturación

```
1  for(int i = 0; i < N; i++) {
2      for(int j = 0; j < M; j++) {
3          IMG[i][j] = min( 255, IMG[i][j] + inc );
4      }
5  }
```

Saturación: incremento de brillo con saturación

(g) Original

(h) +50 de brillo

(i) +100 de brillo

(j) +150 de brillo

(k) +200 de brillo

(l) +250 de brillo
(¿Y la imagen?)

Saturación: instrucciones comunes

Como esto es algo común en el procesamiento de señales, existen instrucciones específicas para operar de esta manera:

- **PADDUSB**/**PSUBUSB**: Suma/Resta enteros sin signo con saturación sin signo.
- **PADDSB**/**PSUBSB**: Suma/Resta enteros con signo con saturación con signo.

En este caso son operaciones de a **byte**.
También existen de a **word**.

Importante

Ver el manual de Intel.

Motivación

Ejemplo

Pasar una imagen RGB a escala de grises.

Motivación

Ejemplo

Pasar una imagen RGB a escala de grises.

Fórmula para pasar imágenes a escala de grises

$$f(r, g, b) = \frac{1}{4} \cdot (r + 2g + b)$$

¡Cuidado!

¿Qué podría pasar con $(r + 2g + b)$?

Motivación: Transformar RGB(0x401080) a grises

Ejemplo

Pasar un pixel `RGB=(0x40, 0x10, 0x80)` a escala de grises.

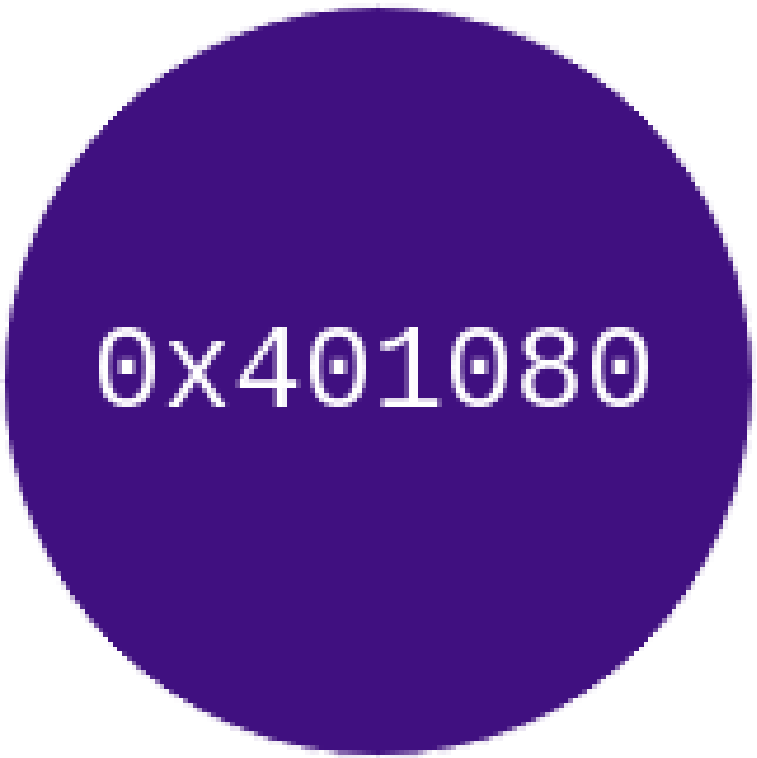

Motivación: Transformar RGB(0x401080) a grises

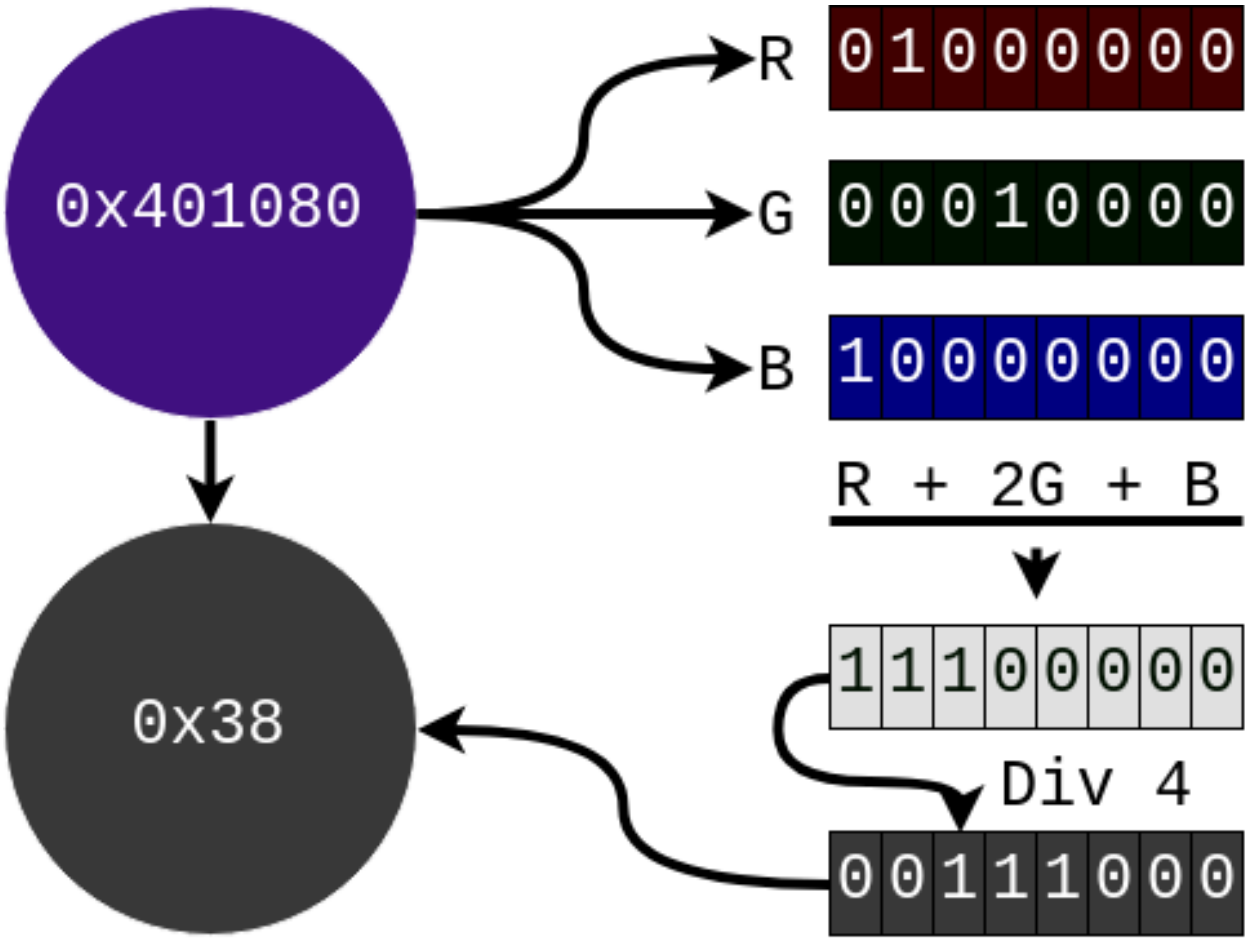

Motivación: Transformar RGB(0x40BF80) a grises

Ejemplo 2

Pasar un pixel `RGB=(0x40, 0xBF, 0x80)` a escala de grises.

Motivación: Transformar RGB(0x40BF80) a grises

¿Cuál es más oscuro?

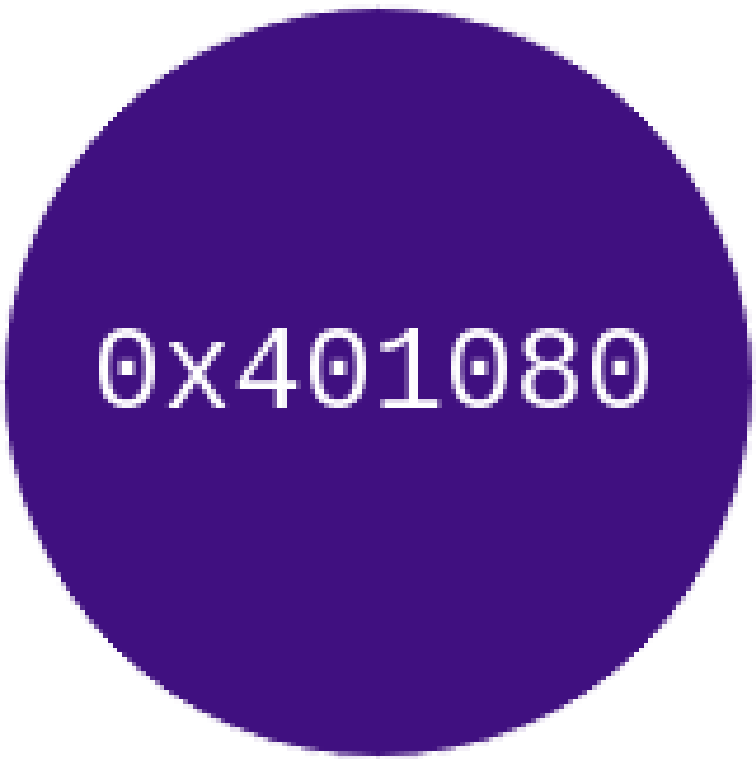

Motivación: Transformar RGB(0x40BF80) a grises

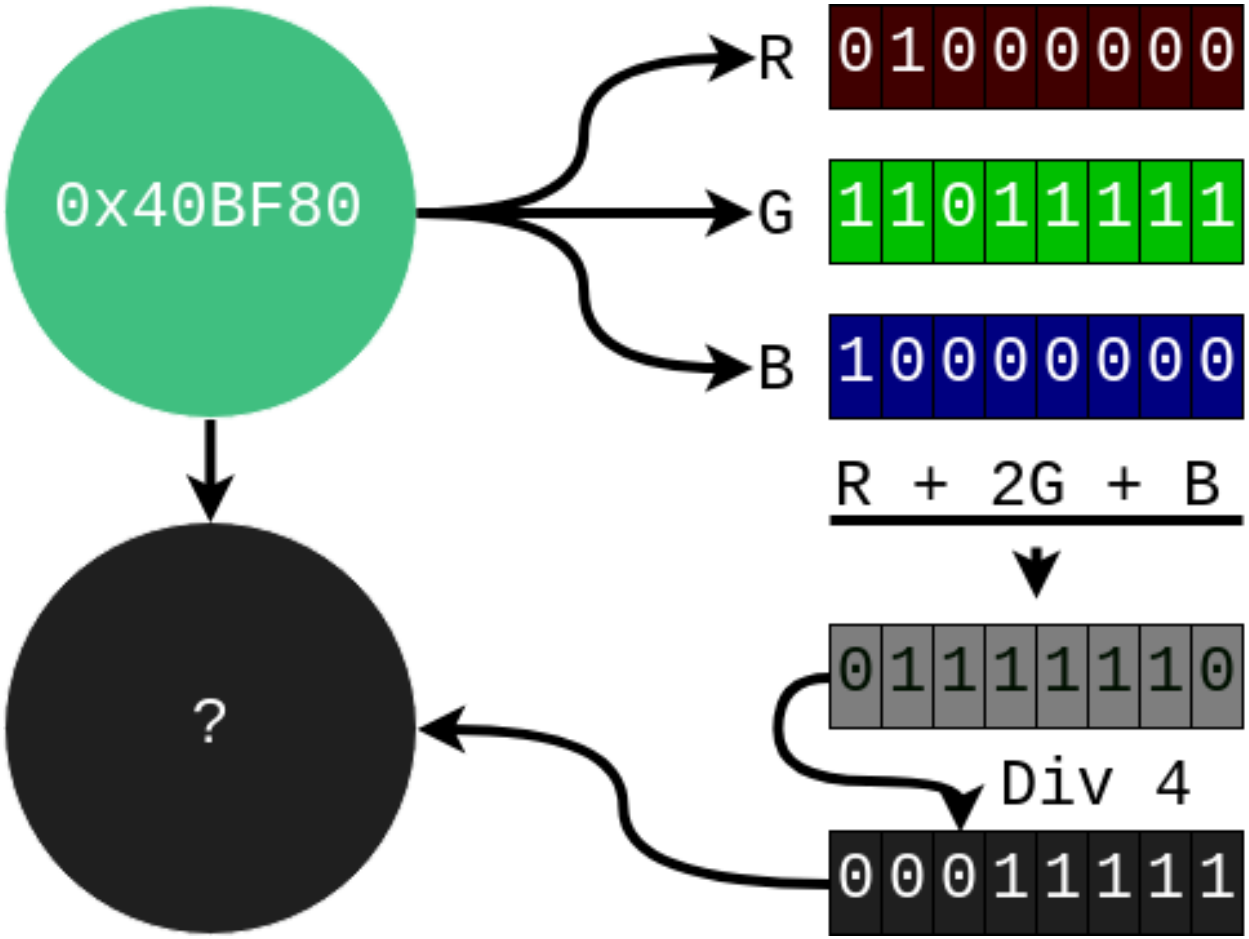

Motivación: Transformar RGB(0x40BF80) a grises

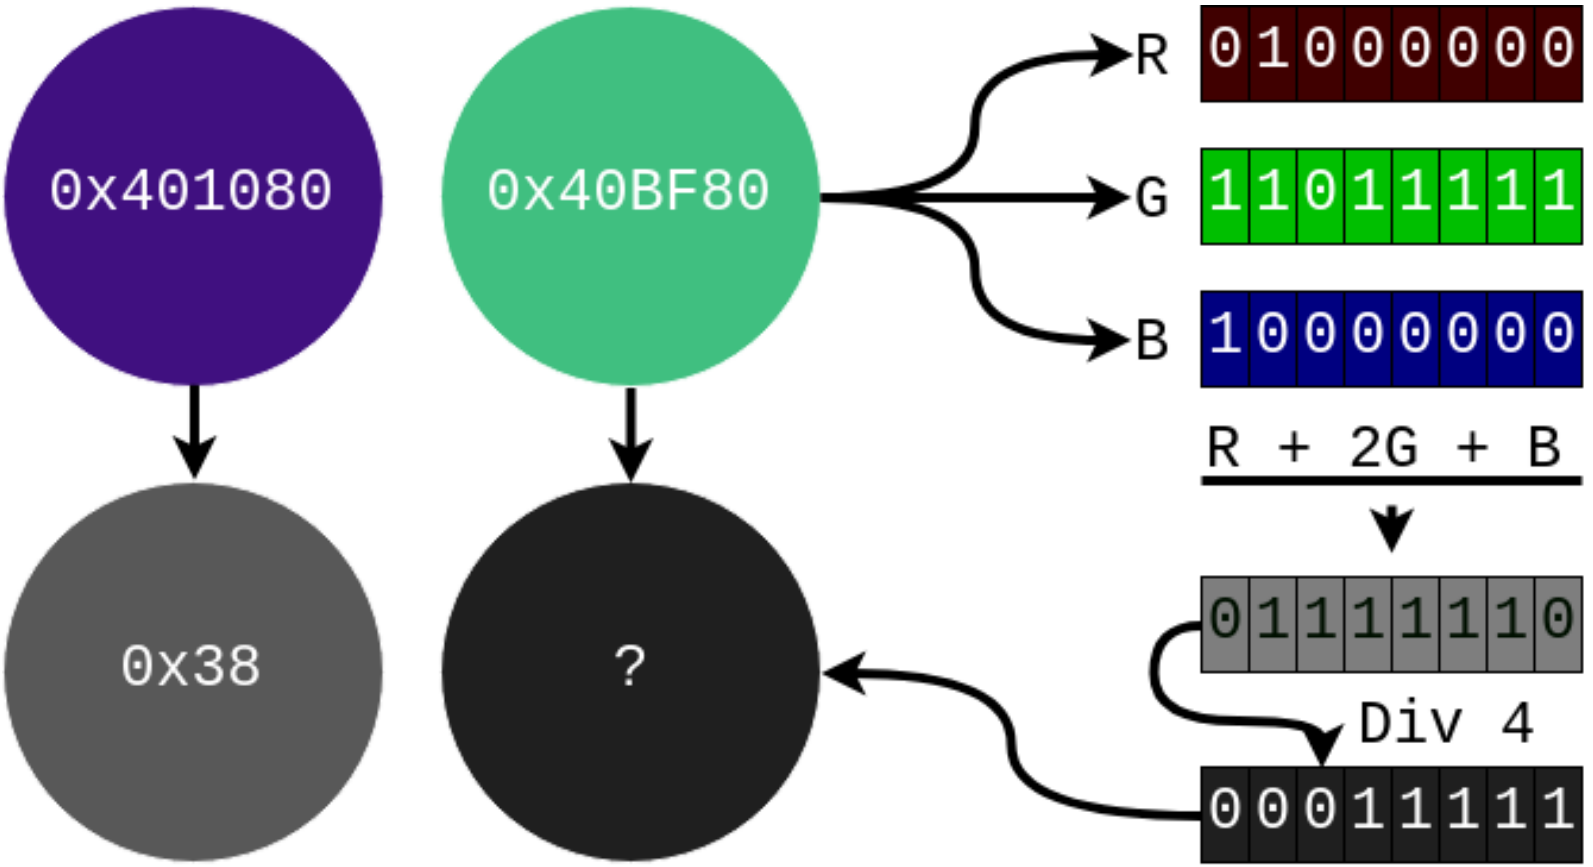

. . .

Motivación: Transformar RGB(0x40BF80) a grises

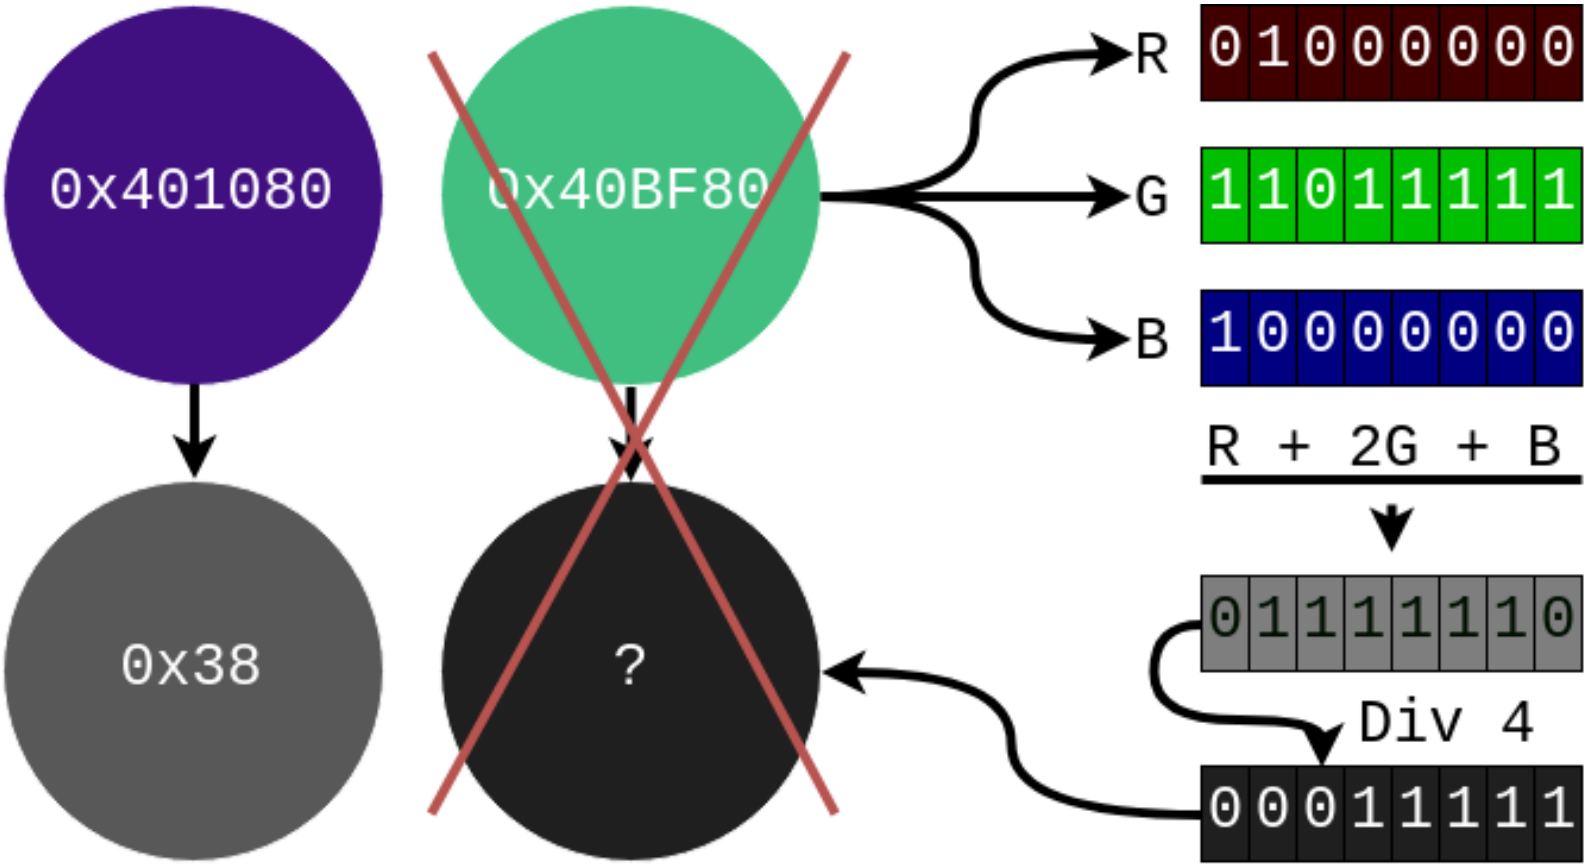

¡...la fórmula no sirve para nada!

Motivación

¿Cuál es el problema?

La representación utilizada (byte) no es suficiente para albergar los resultados intermedios. **Estamos perdiendo información.**

- En esta situación, es necesario manejar los resultados intermedios en un tipo de datos de mayor precisión para no perder información en los cálculos. La precisión original es de **byte**.
- Lo primero que podemos hacer es pasar los datos de **byte** a algo más grande (en este caso nos alcanza con pasar a **word**).
- ¿Cómo lo hacemos?
  Utilizando las instrucciones de desempaquetado.

Empaquetamiento/Desempaquetamiento

Extensión de la representación

Tenemos un registro XMM con bytes sin signo, b_0 hasta b_{15}.

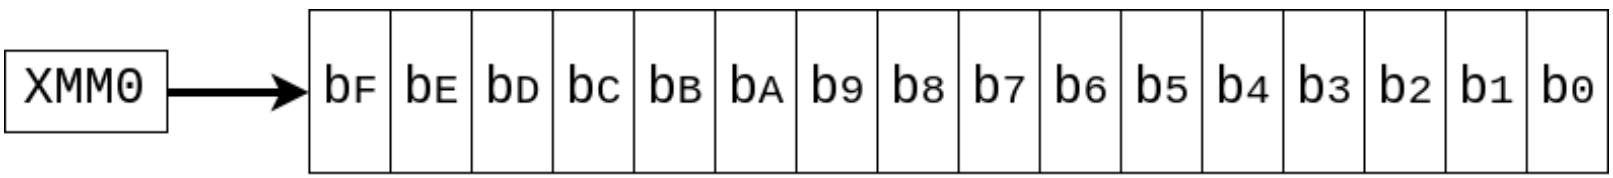

¿Cómo duplicamos la precisión o el tamaño de los datos?

Solamente necesitamos agregar ceros delante de cada número.

Desempaquetar parte baja de XMM0 (idea)

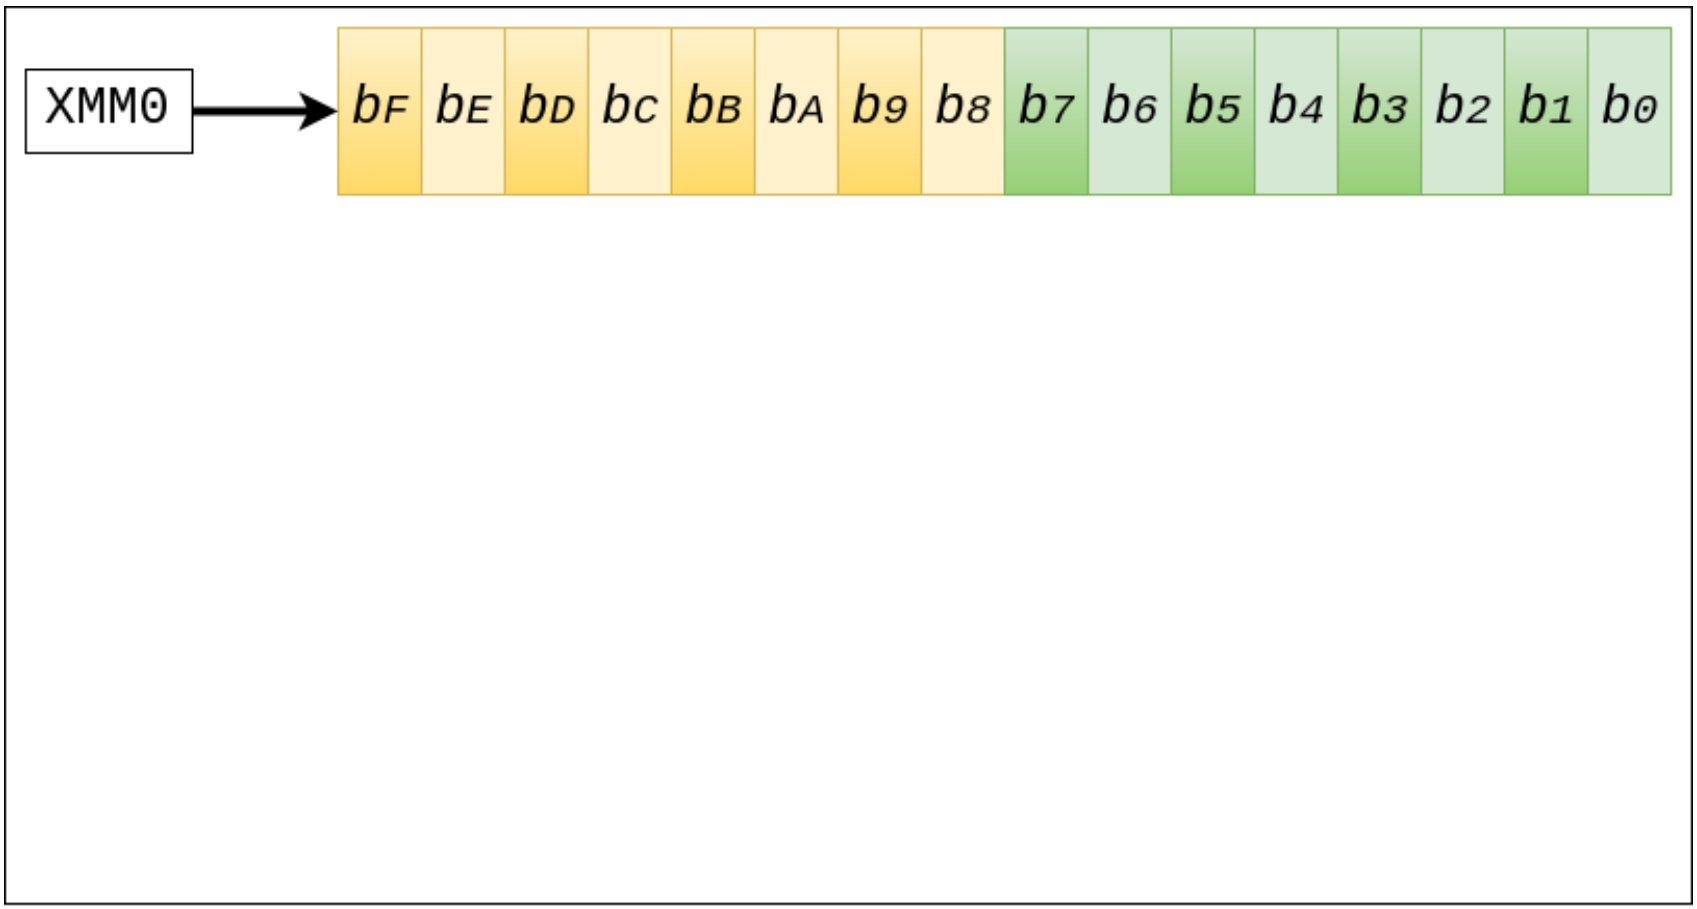

Desempaquetar parte baja de XMM0 (idea)

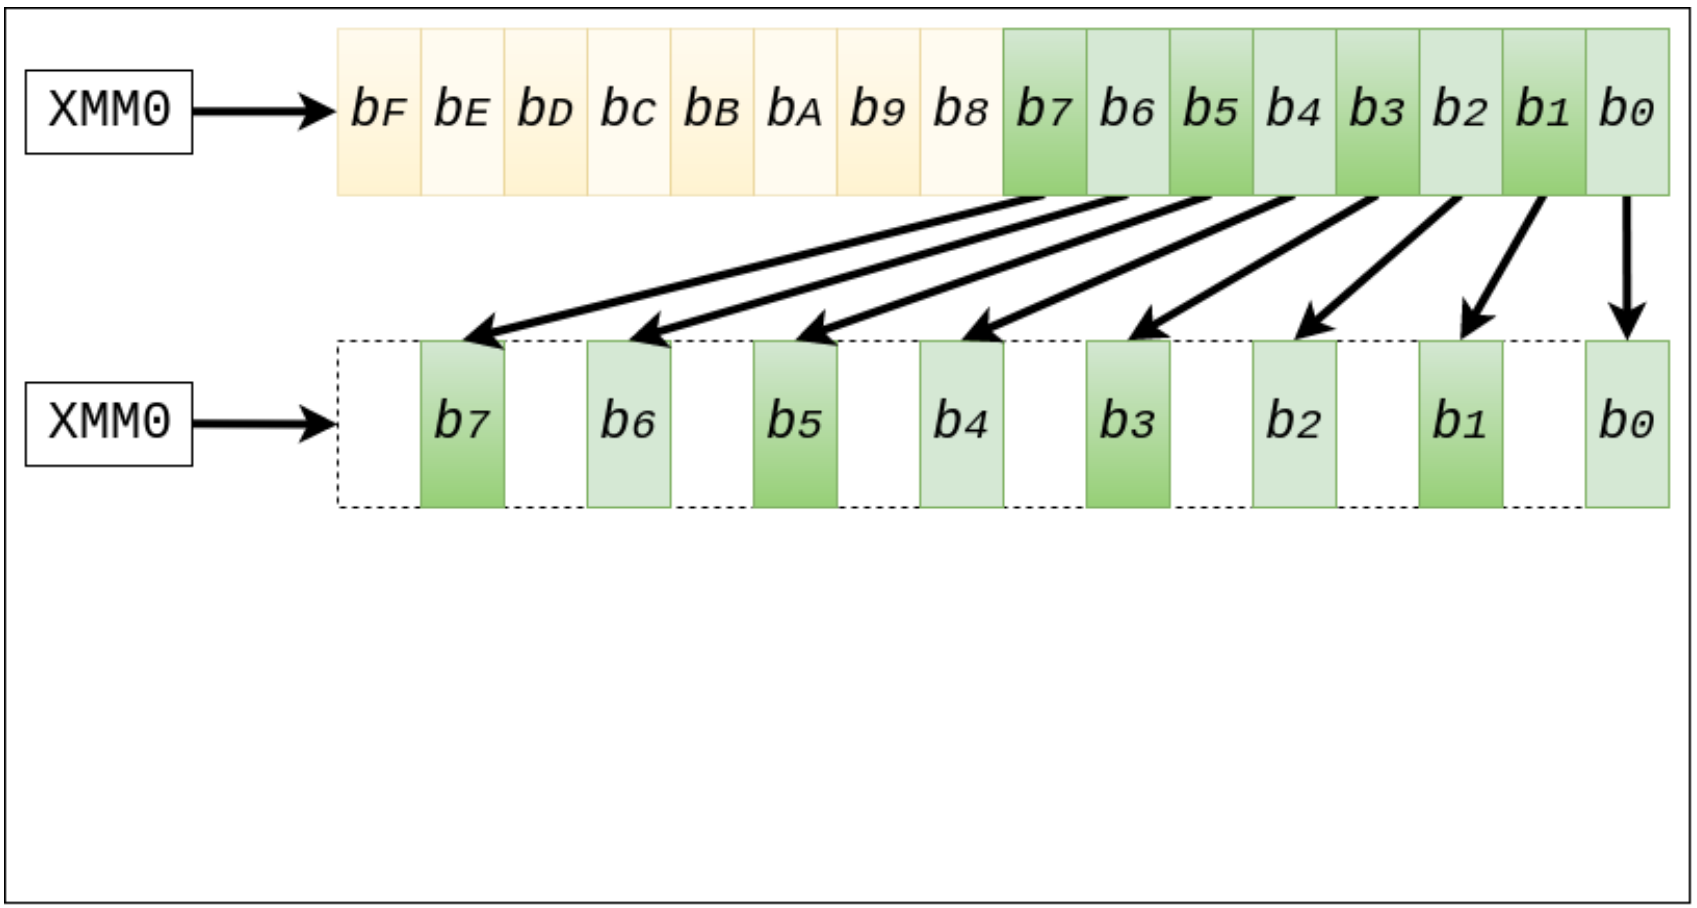

Desempaquetar parte baja de XMM0 (idea)

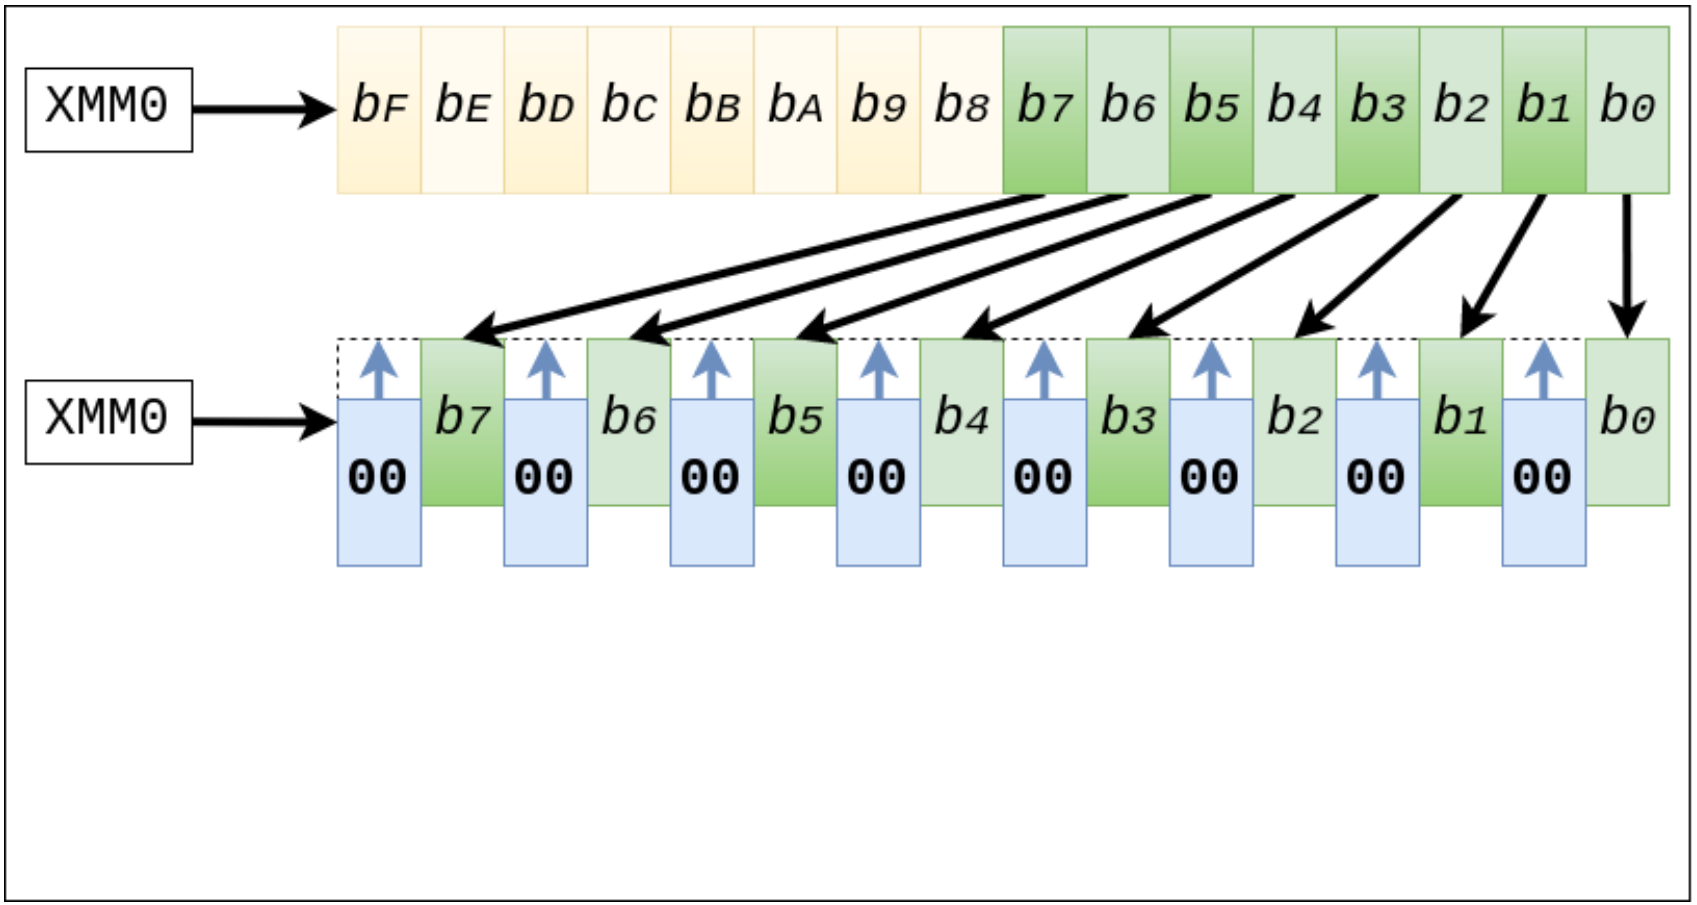

Desempaquetar parte baja de XMM0 (idea)

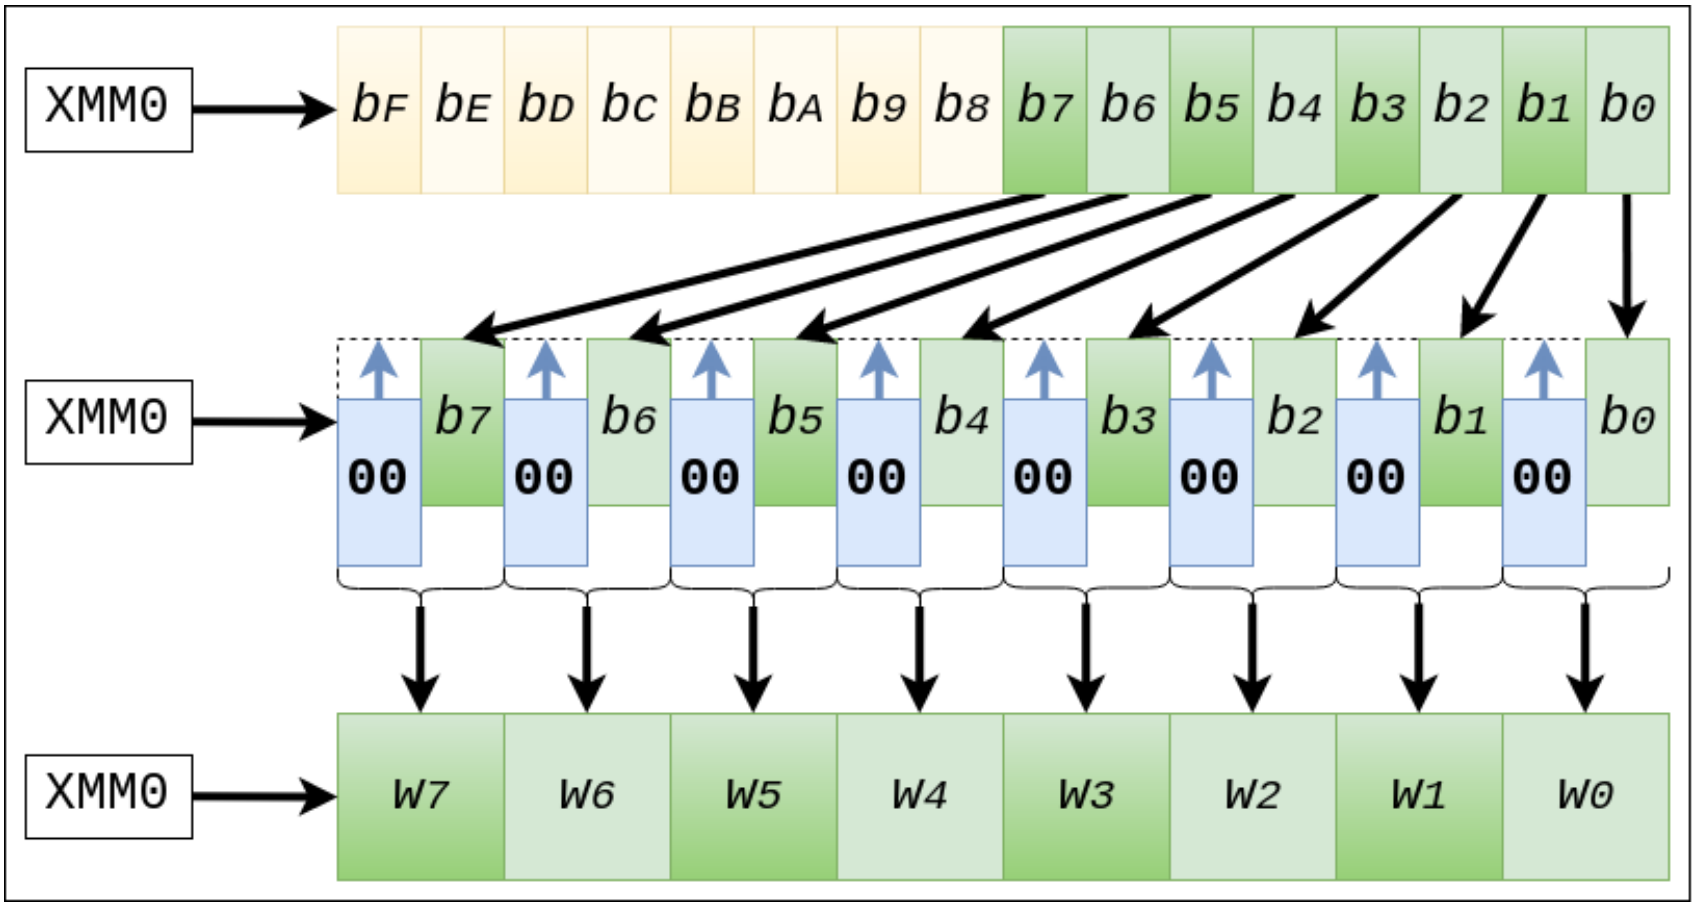

Desempaquetar parte **baja** de XMM0

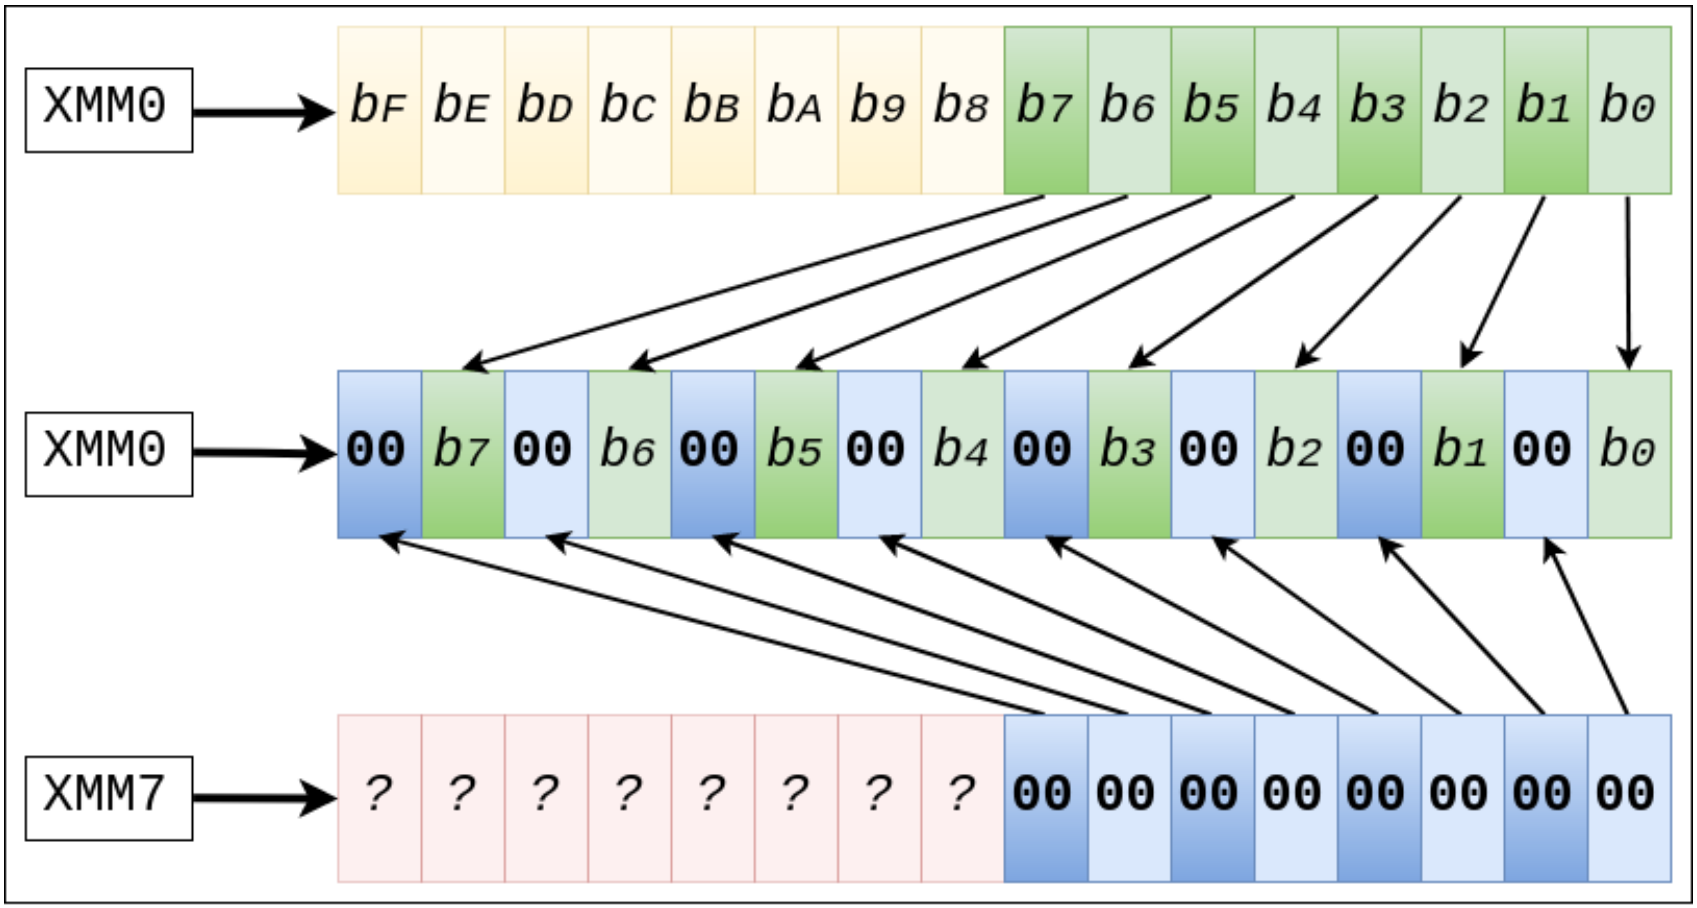

`punpcklbw xmm0, xmm7`

Desempaquetar parte **alta** de XMM0

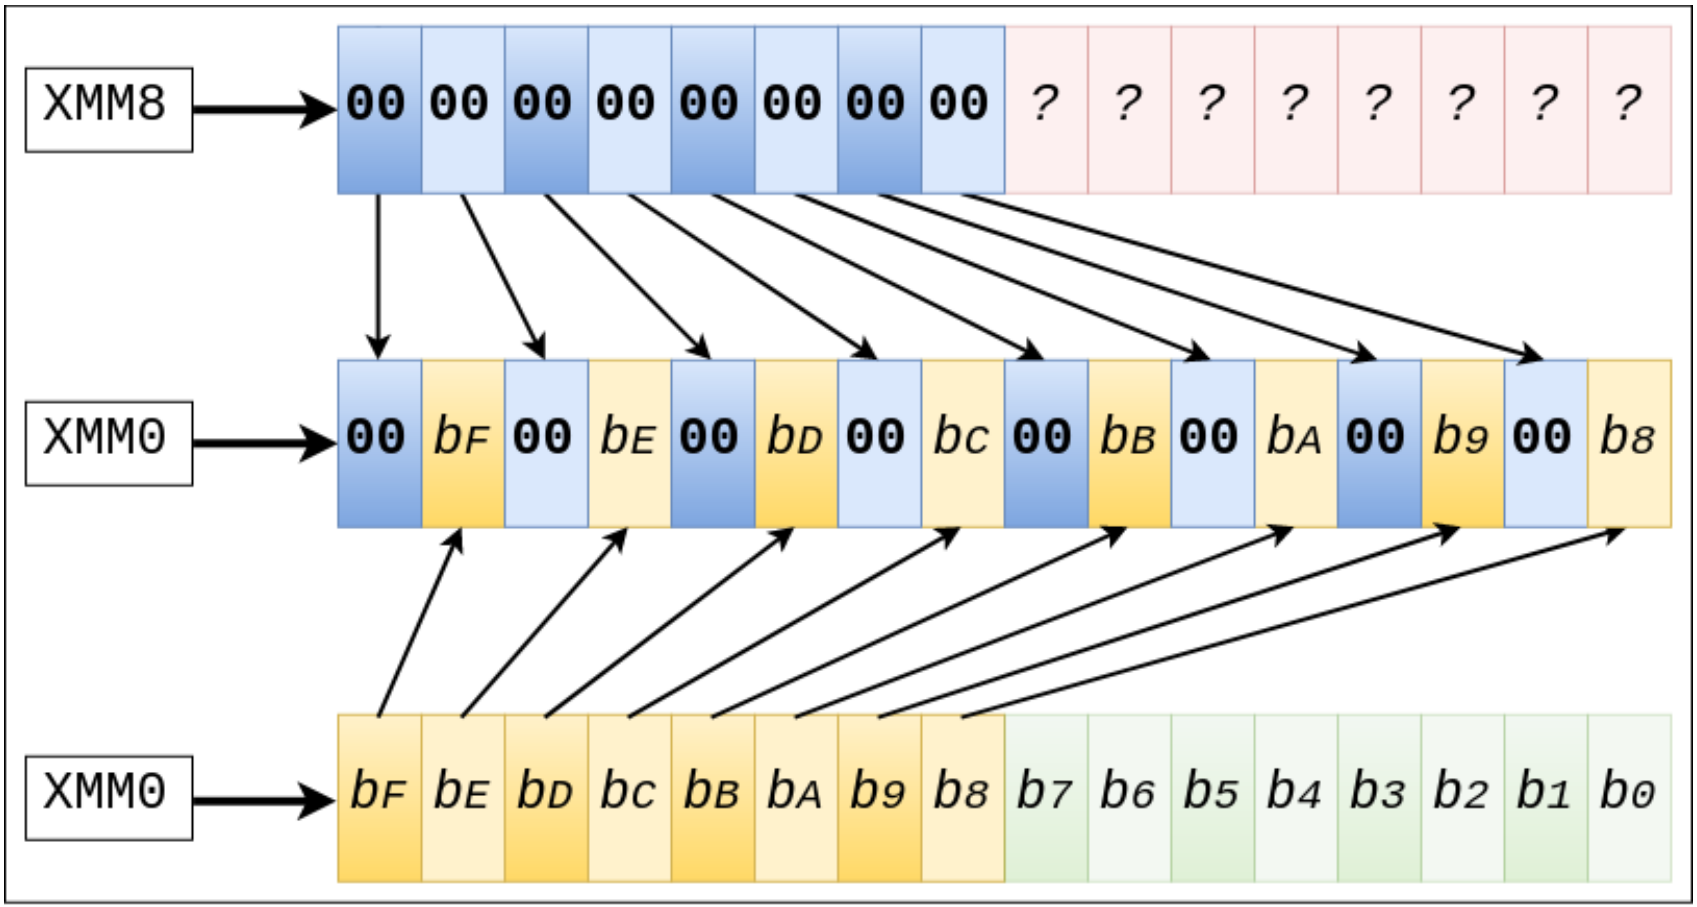

`punpckhbw xmm0, xmm8`

Desempaquetamiento de ambas partes de XMM0

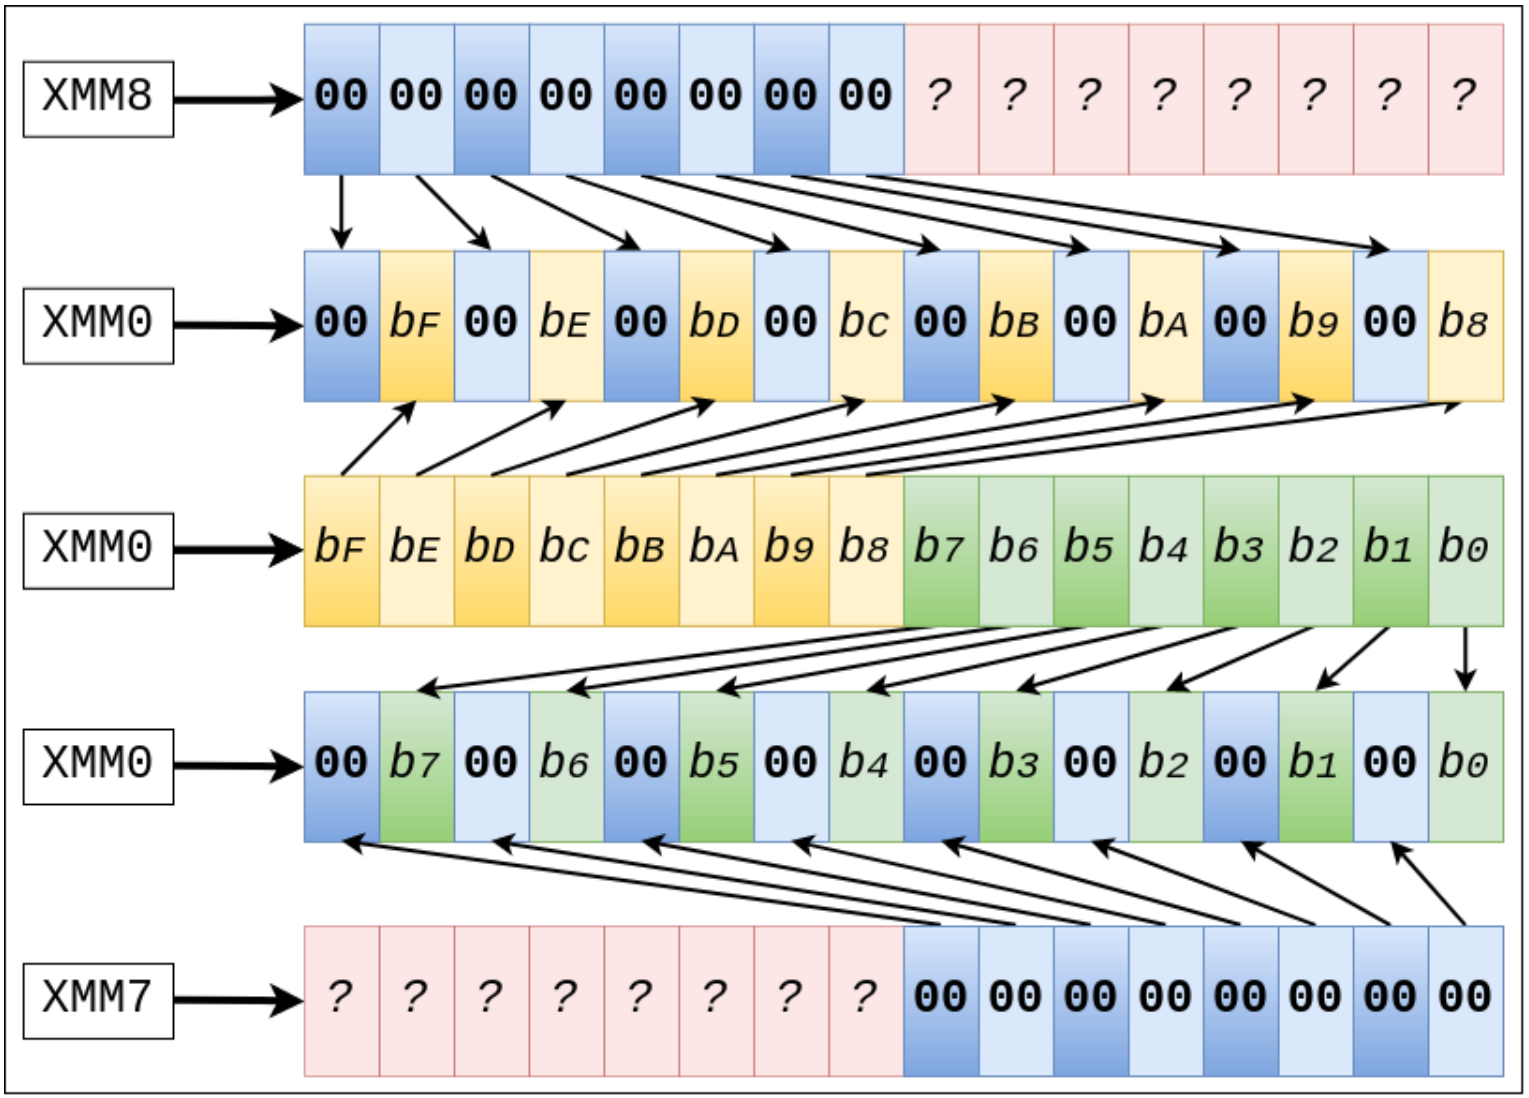

¿Está bien esto?

Desempaquetamiento de ambas partes de XMM0

¡Importante! Para evitar errores...

- Antes, **copiamos XMM0 a otro registro** (ejemplo XMM1). ¡Sino... al desempaquetar una parte perdemos la otra!
- En uno vamos a desempaquetar **la parte baja** (con `punpcklbw`), y en el otro **la parte alta** (con `punpckhbw`).
- Para los 0 de padding, **no hace falta usar dos registros distintos**. Se puede usar el mismo registro para ambas operaciones.

Desempaquetamiento de ambas partes de XMM0

Finalmente...

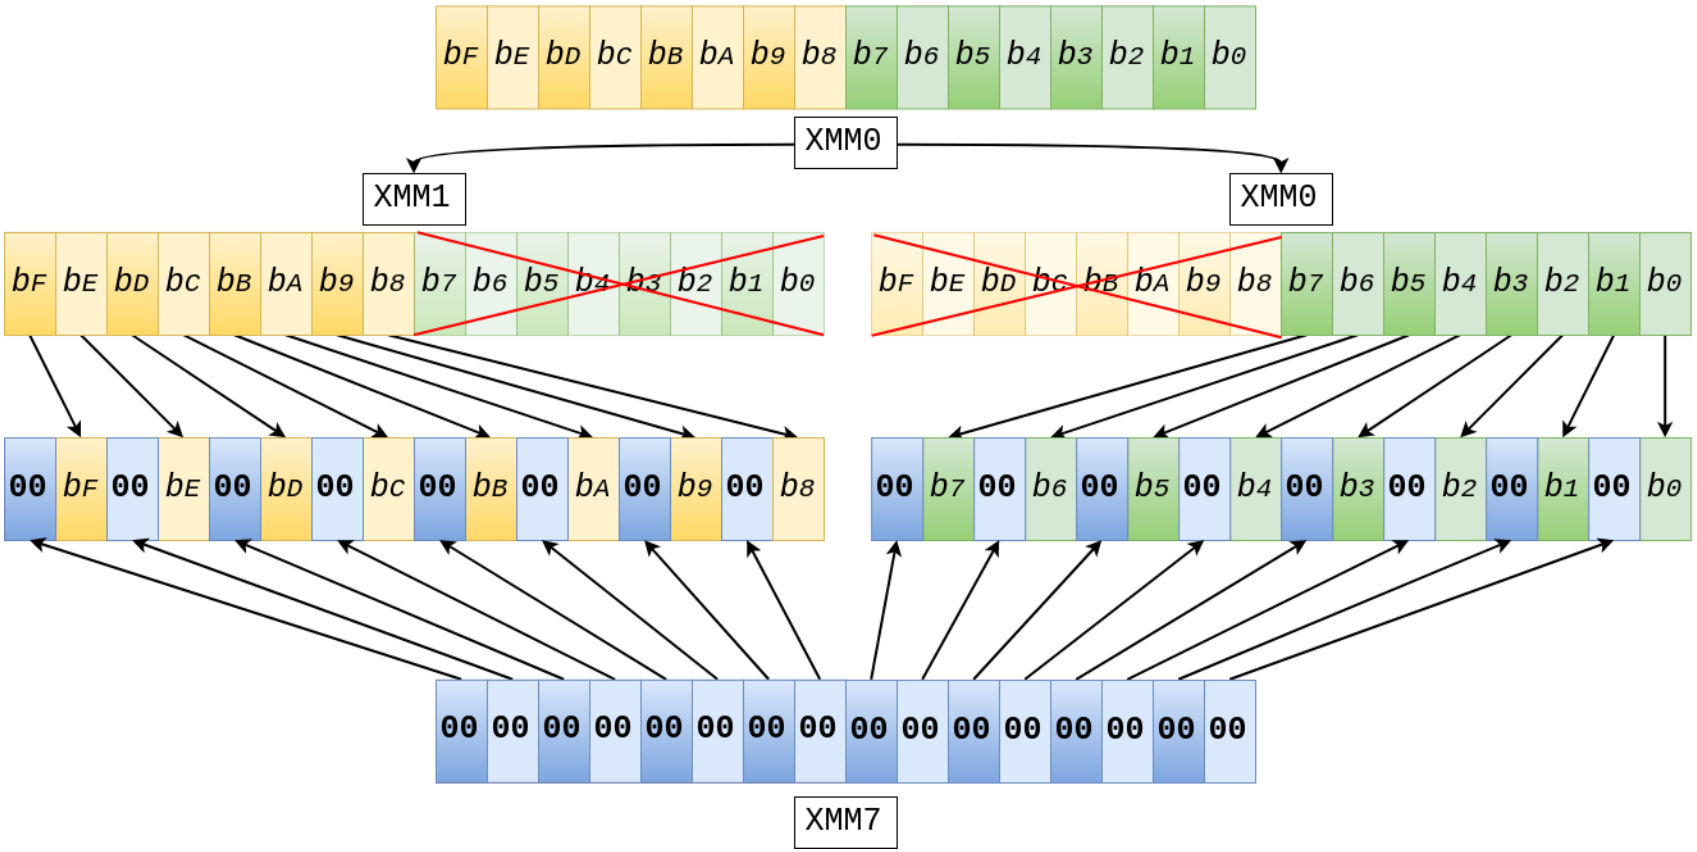

XMM0 desempaquetado en XMM0 y XMM1

Desempaquetamiento: código de ensamblador

Versión en x86_64 assembly

$$\begin{aligned} \textbf{xmm0} &= 0 \,|\, a_7 \,|\, \ldots \,|\, 0 \,|\, a_0 \\ \textbf{xmm1} &= 0 \,|\, a_{15} \,|\, \ldots \,|\, 0 \,|\, a_8 \end{aligned}$$

```
1  ; xmm0 = [a15, a14, ..., a1, a0]
2
3  pxor xmm7, xmm7; xmm7 = [0, 0, ..., 0]
4
5  movdqu xmm1, xmm0; xmm1 = [a15, a14, ..., a0]
6
7  punpcklbw xmm0, xmm7; xmm1 = [0, a7, ..., 0, a0]
8  punpckhbw xmm1, xmm7; xmm2 = [0, a15, ..., 0, a8]
```

Ahora cada dato en XMM0 y XMM0 es de tipo **word**.

Empaquetamiento

Después de extender los datos, realizamos las operaciones que necesitamos.

Y al final, tenemos que guardar los datos nuevamente. Y como en este caso representan píxeles de una imagen en escala de grises, deberían seguir siendo bytes, por lo que tenemos que volver a convertirlos a **byte**.

- ¿Cómo hacemos la conversión?
  Empaquetando los datos.

Las instrucciones de empaquetamiento son varias, tienen en cuenta distintos tipos de datos y si los datos tienen signo o no. Por ejemplo, en el caso de **byte** tenemos:

- **packsswb** (saturación con signo)
- **packuswb** (saturación sin signo)

Recapitulando...

Formato de instrucciones:

- **Desempaquetado:** *punpck* + *l/h* + *bw/wd/dq/qdq*
- **Empaquetado:** *pack* + *ss/us* + *wb/dw*
- **Empaquetado:** *pack* + *ss/us* + *wb/dw*

Importante, cosas a tener en cuenta

- ¿Queremos usar la parte alta o la parte baja?
- ¿De qué tipo son los datos?
- Entonces: ¿Qué tipo de saturación tengo que usar?

Empaquetamiento/Desempaquetamiento

Volviendo al ejemplo anterior...

Ya trabajamos con los datos, ahora
los queremos empaquetar nuevamente...

Usamos `PACKUSWB`.

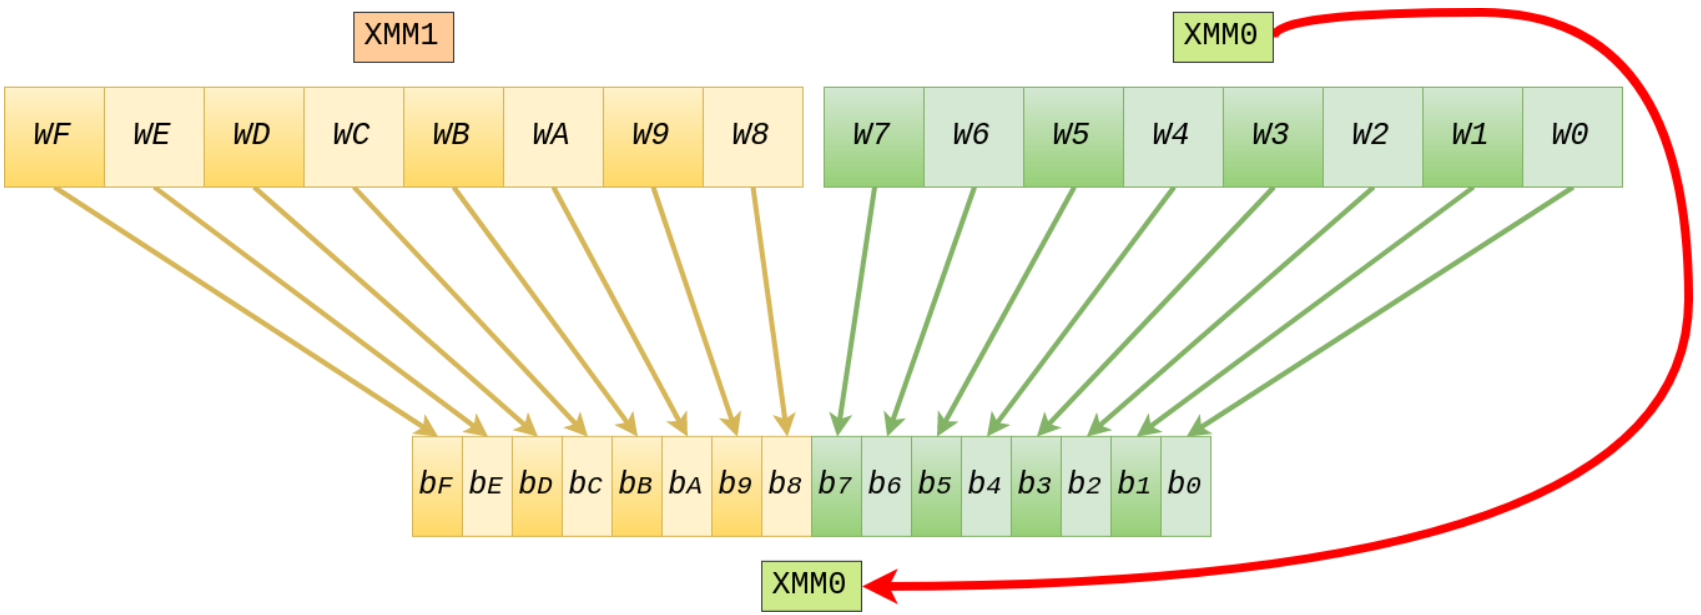

`Empaquetando XMM0 y XMM1 sobre XMM0`

Empaquetamiento/Desempaquetamiento

Versión en x86_64 assembly

$$\begin{aligned} \textbf{xmm0} &= 0 \,|\, a_7 \,|\, \ldots \,|\, 0 \,|\, a_0 \\ \textbf{xmm1} &= 0 \,|\, a_{15} \,|\, \ldots \,|\, 0 \,|\, a_8 \end{aligned}$$

Luego...

packuswb xmm0, xmm1 ; xmm1 $= a_{15} \,|\, a_{14} \,|\, \ldots \,|\, a_1 \,|\, a_0$

Ahora cada dato es de tipo **byte**

Empaquetamiento/Desempaquetamiento

Resumen: paso-a-paso para trabajar en estos casos

- Leer los datos a procesar.
- Extender la precisión o tamaño de los datos (*unpack*).
- Hacer las cuentas que tenemos que hacer.
- Volver a la precisión o tamaño original (*pack*).
- Guardar los datos procesados.

Comparación

En **SSE** también existen instrucciones de comparación, aunque se comportan un poco diferente a las que veníamos usando.

Ejemplo

Tenemos 8 **words** en xmm1, y queremos saber cuáles de ellos son menores a cero.

Ejemplo

$$\textbf{xmm1} = 1000\,|\,-456\,|\,-15\,|\,0\,|\,100\,|\,234\,|\,-890\,|\,1$$

```
pxor xmm7, xmm7          ; xmm7 = 0|0|...|0
pcmpgtw xmm7, xmm1       ; xmm7 > xmm1 ?
```

El resultado de la comparación **queda en xmm7**.

$$\textbf{xmm7} = 0x0000\,|\,0xFFFF\,|\,0xFFFF\,|\,0x0000\,|\,0x0000\,|\,0x0000\,|\,0xFFFF\,|\,0x0000$$

¿Qué significa este resultado?

`pcmpgtw` compara **word** a **word**. Si se cumple la condición, entonces setea todo en **unos** ($0xFFFF$), sino en **ceros**.

Comparación: ejemplos comunes de uso

Podríamos usar el registro obtenido para:

- **Extender el signo:**

  Aprovechando que los números negativos se extendienden con 1s, y los positivos con 0s. Por ejemplo:

  - `-5 = 1011` se extiende a `1111 1011`
  - `5 = 0101` se extiende a `0000 0101`

- **Generar máscaras:**

  Muy útiles para **filtrar algunos elementos del registro**. Luego, con los restantes, podemos hacer lo que necesitemos. Por ejemplo, combinar la máscara con instrucciones como `PAND`, `POR`, `PXOR`, etc.

Comparación: ejemplo de extensión de signo

Ejemplo

Tenemos 8 **words** en xmm1, y queremos extenderlos a **doubles**, pero preservando el signo.

Código ensamblador

$$\textbf{xmm1} = 1000\,|\,-456\,|\,-15\,|\,0\,|\,100\,|\,234\,|\,-890\,|\,1$$

```
1  ; Comparo sobre XMM7
2  pxor xmm7, xmm7; xmm7 = [0, 0, ..., 0, 0]
3  pcmpgtw xmm7, xmm1; [xmm7>xmm1?...]
4
5  ; Luego, extiendo preservando signo
6  movdqa xmm2, xmm1; copio xmm1 a xmm2
7  punpckhwd xmm1, xmm7; xmm1 = [1000, -456, -15, 0]
8  punpcklwd xmm2, xmm7; xmm2 = [100, 234, -890, 1]
```

Comparación: ejemplo de uso de máscaras

Ejemplo

Tenemos 8 **words** en `XMM1`, y queremos sumarle 3 a todos los que sean menores a 0.

$$\textbf{xmm1} = [1000 \mid -456 \mid -15 \mid 0 \mid 100 \mid 234 \mid -890 \mid 1]$$
$$\textbf{xmm3} = [3 \mid 3 \mid 3 \mid 3 \mid 3 \mid 3 \mid 3 \mid 3]$$

Generamos el registro con la comparación en `XMM7`.

Código ensamblador

```
1    pxor xmm7, xmm7; xmm7 = [0, 0, ...., 0, 0]
2    pcmpgtw xmm7, xmm1; [xmm7>xmm1?...]
```

Comparación: ejemplo de uso de máscaras

Código ensamblador: Cargamos, y filtramos la máscara de 3s.

```
1  section .data
2      align 16
3      mascara3: times 8 DW 3 ; 8 veces 0x0003
4      ;mascara3 = [3, 3, 3, 3, 3, 3, 3, 3]
5  section .text
6      ...
7      movdqa xmm2, [mascara3]
8      pand   xmm7, xmm2; xmm7 = [0,3,3,0,0,0,3,0]
```

$$\texttt{xmm7} = [0, 3, 3, 0, 0, 0, 3, 0]$$

Ahora, la máscara tiene 3 sólo donde nos interesa.

Comparación: ejemplo de uso de máscaras

Código ensamblador: Finalmente, sumamos.

```
1 ; xmm1 = [1000, -456, -15, 0, 100, 234, -890, 1]
2 ; xmm3 = [0, 3, 3, 0, 0, 0, 3, 0]
3 paddw xmm1, xmm7
```

$$\texttt{xmm1} = [1000, -453, -12, 0, 100, 234, -887, 1]$$

Ejercicio completo

Consigna

Hacer una funcion sumar que tome un puntero a un array de shorts como primer parametro, y un entero con el largo del array como segundo parametro y que modifique el array de shorts, sumandole 3 a las posiciones en que el valor sea negativo.

Aridad de la función

```
sumar(short* S, int len);
```

Ejercicio completo

```
1  section .data:
2          align 16 // Para que hago esto?
3          mascara: times 8 DW 3
4
5  section .text:
6
7  ; sumar(short* P, int len)
8  ; RDI = P
9  ; ESI = len
10 sumar:
11         ; armo el stackframe
12         push rbp
13         mov rbp, rsp
```

Ejercicio completo

```
14          ; muevo el largo al registro contador (C),
15          ; y divido por 8
16          // por que estoy dividiendo por 8?
17          xor rcx, rcx
18          mov ecx, esi
19          shr rcx, 3
20
21          ; muevo la mascara de 3s a un registro XMM
22          // por que muevo la mascara a un registro
23          // en vez de usarla directamente?
24          movdqa xmm2, [mascara]
25          // por que estoy usando MOVDQA y no MOVDQU?
```

Ejercicio completo

```
26      .ciclo:
27          ; traemos el dato de la memoria
28          movdqu xmm0, [rdi + rcx*8 + (-8)]
29          // por que estoy usando MOVDQU y no MOVDQA?
30
31          ; limpiamos el registro xmm7
32          pxor xmm7, xmm7
33
34          ; comparamos los words contra 0
35          pcmpgtw xmm7, xmm0; xmm7 = [0>xmm0?, ...]
36
37          ; hago un and entre xmm7 y los 3
38          pand xmm7, xmm2; xmm7 = [0>xmm0?0:3, ...]
39          ; el resultado que queda es 0 cuando xmm0>=0
40          ; y 1111111... cuando es negativo
```

Ejercicio completo

```
41          ; sumo la mascara al registro xmm0
42          paddw xmm0, xmm7
43          ; xmm0 queda con el valor original si era
44          ; no negativo, o el valor+3 si era negativo.
45
46          ; guardo el dato en memoria
47          movdqu [rdi + rcx*8 + (-8)], xmm0
48
49          ; itero el ciclo hasta que rcx sea 0
50          loop .ciclo
51
52      ; desarmo el stackframe
53      pop rbp
54      ret
```